

Konuşmadan Duygu Tanıma — Proje Raporu

YAP 470 / BİL 570 — Grup 23 — Ahmet Babagil (211101067) Tüm sonuçlar CREMA-D ve MELD gerçek verisiyle, denek-bağımsız protokolle elde edilmiştir. Tek istisna wav2vec2 transfer-öğrenme satırıdır: GPU (RTX 5080) gerektirdiğinden bu makinede koşulmamış, kod ve talimatları hazırdır (docs/GPU_WAV2VEC2.md). Kod ve tüm çıktılar: <https://github.com/AhmetBabagil/speech-emotion-recognition>.

1. Problem ve Amaç

Kısa bir konuşma kaydından, **yalnızca sesin akustik/prozodik özelliklerine** (ton, perde, tempo, enerji) dayanarak ifade edilen baskın duygunun otomatik tanınması. Metin/ASR veya dil modeli **kullanılmaz**. Problem çok-sınıflı, tek-etiketli bir ses sınıflandırma problemidir.

Ortak 6 duygu: **angry, disgust, fear, happy, neutral, sad**.

2. Veri Setleri

Veri Seti	Tür	Koşul	Kayıt (ortak 6)	Konuşmacı
CREMA-D	Oyunculu	Stüdyo (kontrollü)	~7.442	91 oyuncu
MELD	Diyalog (TV)	Gerçek-ortam	~10.000 (surprise çıkarıldı)	Çok sayıda

- Etiket eşlemesi:** CREMA-D ANG/DIS/FEA/HAP/NEU/SAD → kanonik 6 sınıf; MELD anger/disgust/fear/joy/neutral/sadness → kanonik 6 sınıf (joy→happy , sadness→sad), surprise ortak sınıflar dışında olduğundan atılır.
- Birleştirilmiş manifest:** data/processed/manifest.csv (path, corpus, speaker, split, emotion, label_idx).
- CREMA-D sınıf dağılımı (gerçek):** angry/disgust/fear/happy/sad = 1271, neutral = 1087 (neutral'de yoğunluk seviyesi olmadığından daha az).
- MELD sınıf dağılımı dengesizdir (neutral baskın) → makro-F1 ve dengeli doğruluk raporlanır.

3. Yöntem

Öznitelikler. (a) Temel model için MFCC özet istatistikleri (MFCC + Δ + $\Delta\Delta$ 'nin zaman üzerinden ortalama/std → 240 boyutlu vektör); (b) derin modeller için log-mel spektrogram (n_mels=64 , 16 kHz).

Modeller. 1. **Temel (baseline):** MFCC istatistikleri → StandardScaler → SVM (RBF) / LogReg / RandomForest. (sklearn) 2. **CNN:** log-mel spektrogram üzerinde 4 evrişim bloğu + global ortalama havuzlama + doğrusal sınıflandırıcı. (PyTorch) 3. **Transfer öğrenme:** ön-eğitilmiş wav2vec2-base üzerine sınıflandırma başlığı (ince ayar). (HuggingFace transformers)

Yarı-denetimli / denetimsiz bileşen. Önerideki yöntem maddesi gereği, MFCC öznitelikleri üzerinde: (a) **denetimsiz K-Means kümeleme** (K = 6), (b) **azaltılmış etiketle eğitim** (etiket eğrisi: %1–%100), ve (c) **yarı-denetimli kendi-kendine eğitim** (güvenli sözde-etiketleme) incelenir (ser/semisupervised.py).

Değerlendirme protokolü. - **Denek-bağımsız (speaker-independent)** bölme: bir konuşmacı yalnızca tek bir kümede (eğitim/doğrulama/test) yer alır — duygu yerine sesi ezberlemeyi önler. - **Çapraz-veri-seti (cross-corpus):** A üzerinde eğit, B'nin tamamında test et (ve tersi) — alan kayması (domain shift) altında genelleme ölçülür. - Sınıf dengesizliği için **dengeli sınıf ağırlıkları**; metrikler: doğruluk, dengeli doğruluk, **makro-F1**, ağırlıklı-F1, sınıf-bazlı kesinlik/duyarlılık/F1 ve **karışıklık matrisi**.

4. Deney Düzeni

- Donanım: eğitim RTX 5080 (16 GB, CUDA, AMP); geliştirme CPU.
- Tekrarlanabilirlik: sabit tohum (`seed=42`), kaydedilen `config.yaml` .
- Komutlar: bkz. `README.md` . Tüm matris: `python scripts/run_all.py` . Yarı-denetimli/denetimsiz analiz: `python scripts/semisupervised.py` .

5. Sonuçlar


```
python scripts/aggregate_results.py → outputs/results.csv / results.md .
```


5.1 Veri-seti-içi (within-corpus)

Deney	Doğruluk	Dengeli Doğr.	Makro-F1
baseline_cremad (MFCC+SVM)	0.523	0.520	0.520
cnn_cremad (log-mel CNN)	0.555	0.554	0.557
cnn_meld (log-mel CNN, denek-bağımsız)	0.304	0.253	0.206
wav2vec2_cremad	[GPU'da çalıştırılacak — bkz. docs/GPU_WAV2VEC2.md]		

Temel model vs CNN (CREMA-D, denek-bağımsız, şans = %16.7): Klasik MFCC+SVM temel modeli makro-F1 **0.520** verirken, log-mel spektrogram üzerinde eğitilen CNN makro-F1 **0.557**'ye çıkar (~+3.7 puan) — derin modelin beklenen üstünlüğü. CNN en kolay sınıf `angry` (F1 0.65), en zor `fear` (F1 0.47); 22 epoch, en iyi epoch 14 (erken durdurma). `cnn_meld` ve `wav2vec2` derin eğitimleri RTX 5080 makinesinde çalıştırılmak üzere hazırdır (bu geliştirme makinesi yalnızca CPU).

CREMA-D temel model (solda) ve CNN (sağda) karışıklık matrisleri:





5.2 Çapraz-veri-seti (cross-corpus) — GERÇEK SONUÇLAR

İki model için de denek-bağımsız çapraz-veri-seti matrisi (makro-F1):


Eğitim → Test	MFCC+LogReg	log-mel CNN
CREMA-D → CREMA-D (içi)	0.502	0.557
MELD → MELD (içi)	0.188	0.206
CREMA-D → MELD (çapraz)	0.083	0.100
MELD → CREMA-D (çapraz)	0.191	0.105

Görseller: `figures/crosscorpus_macro_f1.png` (LogReg), `figures/cnn_crosscorpus_macro_f1.png` (CNN); ham veriler `outputs/*_crosscorpus/summary.csv`.

Bulgu 1 — alan kayması (projenin temel katkısı): Her iki modelde de köşegen (veri-seti-içi) değerleri köşegen-dışı (çapraz) değerlerden belirgin biçimde yüksektir. CNN, CREMA-D'de makro-F1 **0.557** elde ederken aynı model MELD'de **0.100**'e çöker (~5.6 kat düşüş). Bu, stüdyo→gerçek-ortam genellemesinin somut, ölçülmüş kanıtıdır ve önerideki "literatürde kolayca yükselmeyen zorlu problem" tezini doğrular.

Bulgu 2 — daha güçlü model alan kaymasını çözmez: CNN, veri-seti-içi başarımı LogReg'e göre belirgin artırır (CREMA-D 0.502→0.557, MELD 0.188→0.206); ancak çapraz-veri-seti başarımı düşük kalır, hatta MELD→CREMA-D yönünde CNN (0.105) LogReg'den (0.191) **daha kötü** genelleştirir. Yani daha yüksek

kapasite, alana özgü ipuçlarını daha çok ezberleyip çapraz-alan genellemesini iyileştirmeyebilir — bu, alan kaymasının kapasiteyle çözümediğini gösteren öğretici bir sonuçtur.



Bulgu 3 — metrik seçimi: MELD kendi içinde de zordur (gerçek-ortam koşulları + neutral baskınlığı). Bu nedenle doğruluk yerine **makro-F1** ve **dengeli doğruluk** raporlanması kritiktir (her şeye "neutral" demek yüksek doğruluk ama düşük makro-F1 verir).


5.3 Yarı-denetimli ve denetimsiz bileşen (CREMA-D) — GERÇEK SONUÇLAR

Önerideki yöntem maddesi gereği, MFCC öznelikleri üzerinde üç analiz yapıldı (`scripts/semisupervised.py`).

(a) Denetimsiz kümeleme (K-Means, K = 6). Hiç etiket kullanmadan kümeleme:

Metrik	Değer	Yorum
Adjusted Rand Index (ARI)	0.099	düşük — kümeler duyguyla zayıf örtüşüyor
Normalized Mutual Info (NMI)	0.161	düşük-orta
Hungarian-eşlemeli doğruluk	0.272	şansın (0.167) üzerinde
Hungarian-eşlemeli makro-F1	0.256	—


Akustikte duygu yapısı **vardır** (etiket görmeden bile şansın üzerine çıkılıyor), ancak **zayıftır**: akustik değişkenliğin baskın eksenini duygu değil, konuşmacı ve cümle kimliğidir. Bu, denetimsiz tek başına SER için yetersiz olduğunu gösterir.



(b) Azaltılmış etiketle eğitim (etiket eğrisi, LogReg).

Etiket oranı	#Etiket	Makro-F1
%1	64	0.329
%5	317	0.370
%10	638	0.383
%25	1.593	0.436
%50	3.191	0.505
%100	6.382	0.515

Görev **etiket-verimlidir**: yalnızca %1 etiketle (64 örnek) makro-F1 0.33 (şansın 2 katı), %25 etiketle tam başarımın ~%85'i elde edilir; %50'den sonra kazanç azalır.



(c) **Yarı-denetimli kendi-kendine eğitim (self-training, %10 tohum).** %10 etiketli tohumdan başlayıp güven eşiği 0.80 ile 5.014 sözde-etiket eklendi: supervised-only makro-F1 **0.385** → self-training **0.384** ($\Delta = -0.001$). Sözde-etiketleme burada **yardımcı olmadı**; taban sınıflandırıcının doğruluğu orta düzeyde olduğunda kendi hatalarını pekiştirir — literatürde bilinen, dürüst bir negatif sonuçtur.

6. Tartışma

Temel model vs CNN vs (denetimsiz/yarı-denetimli). Denetimli ilerleme açıktır: MFCC+SVM (0.520) → log-mel CNN (0.557). Buna karşılık etiketsiz/az-etiketli yaklaşımlar sınırlı kalır — denetimsiz kümeleme yalnızca 0.256 makro-F1, self-training ise denetimli tabanın üzerine çıkamadı. Çıkarım: bu görevde **etiketli veri kritiktir**; ancak görev etiket-verimlidir (az etiketle makul başarımlar alınır).

Stüdyo ↔ gerçek-ortam farkı. CREMA-D (kontrollü, dengeli) içinde başarımlar makul (0.52–0.56); MELD (gerçek-ortam, dengesiz) içinde belirgin düşer (0.19–0.21). Fark, MELD'in arka plan gürültüsü, değişken kayıt koşulları ve güçlü neutral baskınlığından kaynaklanır.

Çapraz-veri-seti düşüşünün nedenleri. Köşegen-dışı çöküş (CREMA-D→MELD 0.10), iki korpusun (i) kayıt koşulları, (ii) konuşmacı/demografi dağılımı ve (iii) etiketleme biçimi/öznelliği bakımından farklı dağılımlardan gelmesindendir. Daha yüksek kapasiteli CNN bile bu farkı kapatamadı; aksine MELD→CREMA-D yönünde alana özgü ipuçlarını ezberleyip LogReg'den daha kötü genelleştirdi. Bu, alan kaymasının **kapasiteyle değil**, alan uyarlama (domain adaptation) yöntemleriyle ele alınması gerektiğini düşündürür.

Hangi sınıflar karışıyor. CREMA-D karışıklık matrislerinde en kolay sınıf **angry** (yüksek enerji/perde belirgin), en zor **fear** 'dır (**sad** / **neutra1** ile karışır). MELD'de ise tahminler baskın **neutra1** sınıfına kayar; bu yüzden doğruluk yüksek görünse de makro-F1 düşüktür.

7. Sonuç

Her iki veri setinde (CREMA-D + MELD, ~19.500 kayıt, ortak 6 duygu) çalışan, **denek-bağımsız** ve **çapraz-veri-seti** değerlendirme yapan bir konuşmadan duygu tanıma sistemi geliştirildi. Başlıca bulgular:

1. **Model ilerlemesi işe yarıyor:** CREMA-D'de MFCC+SVM temel modeli (makro-F1 0.520) → log-mel CNN (makro-F1 0.557). Derin model klasik temeli geçti.
2. **Çapraz-veri-seti genelleme zordur (projenin temel bulgusu):** CREMA-D üzerinde eğitilen model kendi test kümesinde makro-F1 0.502 elde ederken MELD üzerinde 0.083'e çöker — stüdyo→gerçek-ortam alan kaymasının somut, ölçülmüş kanıtı.
3. **Metrik seçimi kritiktir:** MELD'in sınıf dengesizliği nedeniyle doğruluk yanıltıcıdır; makro-F1 ve dengeli doğruluk gerçek başarıyı gösterir.
4. **Etiketli veri kritik ama görev etiket-verimli:** Denetimsiz kümeleme akustikte yalnızca zayıf bir duygu yapısı bulur (makro-F1 0.256); buna karşın %25 etiketle tam başarımın ~%85'i elde edilir. Naif yarı-denetimli sözde-etiketleme ek fayda sağlamadı.

Derin wav2vec2 transfer-öğrenme deneyi (GPU gerektirir) RTX 5080 makinesinde aynı kod ve konfigürasyonla çalıştırılmaya hazırdır (bkz. `docs/GPU_WAV2VEC2.md`).

8. Tekrarlanabilirlik ve doğrulama

Kod: <https://github.com/AhmetBabagil/speech-emotion-recognition>. Kurulum ve çalıştırma: `README.md`. Sabit tohum (seed=42), kaydedilen `config.yaml`, tohumlanmış veri artırma ve DataLoader üretici ile sonuçlar tekrarlanabilir. Her deney klasörü `config.yaml`, `history.json`, `test_metrics.json` ve karışıklık matrisini içerir; tüm sonuçlar `scripts/aggregate_results.py` ile toplanır.

Doğrulama notu: Kod, çok-ajanlı düşmanca denetimden geçirildi. Bu denetimlerde, öznitelik ön belleğinin (cache) yalnızca dosya adıyla anahtarlanması nedeniyle MELD'in bölme başına yeniden başlayan `dia{D}_utt{U}` kimliklerinin çakışabileceği bir hata bulundu ve düzeltildi (anahtar artık bölme klasörünü içerir). Tüm MELD/çapraz-veri-seti deneyleri düzeltilmiş ön bellekle yeniden koşuldu; sonuçlar **değişmedi** (MELD başarımı zaten taban seviyesine yakın olduğundan öznitelik gürültüsü makro-F1'i etkilemedi), böylece raporlanan sayılar doğrulanmış oldu. (CREMA-D dosya adları benzersiz olduğundan hiç etkilenmemişti.)