

YAP 470 Final Projesi: Konuşmadan Duygu Tanıma

Bu rapor, CREMA-D veri seti üzerinde konuşmadan duygu tanıma için uygulanan iki yöntemin geliştirme ve değerlendirme sürecini özetler. Tüm sayılar, tablolar ve görseller koşulan deneylerin kayıtlı çıktılarından otomatik üretilmiştir.

- Kod deposu: <https://github.com/AhmetBabagil/speech-emotion-recognition/tree/feat/speech-emotion-recognition>
- Çıktılar ve teslim dosyaları: <https://drive.google.com/drive/folders/1Hbp4WtCGFZjpvQCDxFmqtOmeqg-SMPvW?usp=sharing>

Yönetici Özeti

- Yöntem 1 (mel + CNN) test sonucu: doğruluk 0.6264, macro-F1 0.6282.
- Yöntem 2 (aralık + LSTM/GRU) test sonucu: doğruluk 0.6377, macro-F1 0.6440.
- Her iki yöntem de konuşmacı-bağımsız bölmeyle, sınıf-ağırlıklı cross-entropy ve geçerleme macro-F1 üzerinde erken durdurmayla eğitildi.
- Hiperparametre araması + yerel iyileştirme turu + artırma/dikkat geliştirme aşaması uygulandı; test kümesine yalnızca seçilen modeller dokundu.

Veri Seti ve Bölme

CREMA-D, 91 aktörün 12 cümleyi altı duyguyla (kızgın, tiksinti, korku, mutlu, nötr, üzgün) seslendirdiği 7.442 kayıttan oluşur [1]. Bölme aktör kimliğine göre yapıldı: bir konuşmacının tüm kayıtları tek kümede kalır. Kayıt-bazlı rastgele bölme, aynı sesin hem eğitimde hem testte görünmesine yol açarak sonuçları yapay olarak şişirir [11, 12]; bu nedenle raporlanan tüm sonuçlar konuşmacı-bağımsızdır.

Konuşmacı-bağımsız eğitim/geçerleme/test bölmesi (seed=42).

Küme	Kayıt	Konuşmacı	Oran
Eğitim	5234	64	%70.3
Geçerleme	1148	14	%15.4
Test	1060	13	%14.2

Sınıf dağılımı; hafif dengesizlik ağırlıklı hata fonksiyonuyla telafi edildi.

Duygu	Eğitim	Geçerleme	Test
Kızgın	894	196	181
Tiksinti	894	196	181
Korku	894	196	181
Mutlu	894	196	181
Nötr	764	168	155
Üzgün	894	196	181

Değerlendirme Metrikleri

Altı sınıflı ve hafif dengesiz bu problemde tek başına doğruluk yanıltıcı olabileceğinden dört metrik birlikte raporlandı: doğruluk, dengeli doğruluk (sınıf başına duyarlılık ortalaması; literatürdeki UA karşılığı), macro-F1 (tüm sınıflara eşit ağırlık) ve ağırlıklı F1. Model seçimi ve erken durdurma macro-F1 üzerinden yapıldı [6, 11]. Sınıf bazında kesinlik/duyarlılık/F1 ve karışıklık matrisleri de verildi.

Veri Ön İşleme

- Tüm kayıtlar 16 kHz mono olarak yüklendi (librosa yalnızca sinyal düzeyi öznitelik çıkarımı için kullanıldı; ödev kuralları buna izin veriyor).
- Yöntem 1: 1024 nokta FFT, 256 örnek atlama, 20-8000 Hz aralığında log-mel spectrogram; zaman eksenini ortadan kırpmaya/dolgu ile sabit uzunluğa getirildi [2, 3].
- Yöntem 2: kayıt, sayısı ve genişliği hiperparametre olan eşit aralıklı pencerelere bölündü; aralık başına 44 boyutlu istatistik vektörü çıkarıldı [6, 9].
- Z-skor normalizasyonu YALNIZCA eğitim kümesi istatistikleriyle öğrenilip diğer kümelere uygulandı; bilgi sızıntısı yoktur.
- Öznitelikler, ayar parmak izi içeren bir ön belleğe alınarak deneme turları hızlandırıldı.

Yöntem 1: Log-Mel Spectrogram + CNN

Her kayıt tek kanallı bir log-mel spectrogram görüntüsüne çevrildi ve sıfırdan tanımlanan bir CNN ile sınıflandırıldı. Ağ, Conv-BN-ReLU çiftleri ve 2x2 max pooling içeren bloklardan sonra global average pooling ve tek bir doğrusal katmandan oluşur; hazır ya da önceden eğitilmiş hiçbir model kullanılmadı [2, 4].


Geçerleme kümesinde 11 aday tarandı; ardından kazanan etrafında 8 adaylık yerel iyileştirme turu koşuldu. Seçim ölçütü geçerleme macro-F1 değeridir; test kümesine yalnızca nihai kazanan dokundu.

Geçerleme macro-F1 sırasına göre ilk 12 aday (toplam 19 deneme).

Aşama	Öznitelik	Model	Parametre	En iyi epoch	Geçerleme doğruluk	Geçerleme macro-F1
iyileştirme	64x128 mel	kanallar 32x64x128, dropout 0.3, lr 0.001, batch 16	287654	29	0.5575	0.5531
iyileştirme	64x128 mel	kanallar 32x64x128, dropout 0.2, lr 0.001, batch 32	287654	14	0.5601	0.5528
iyileştirme	64x128 mel	kanallar 64x128x256, dropout 0.3, lr 0.001, batch 32	1146694	19	0.5523	0.5495
iyileştirme	64x128 mel	kanallar 32x64x128, dropout 0.3, lr 0.0005, batch 32	287654	14	0.5505	0.5446
iyileştirme	64x128 mel	kanallar 32x64x128, dropout 0.4, lr 0.001, batch 32	287654	25	0.5462	0.5441
arama	64x128 mel	kanallar 32x64x128, dropout 0.3, lr 0.001, batch 32	287654	14	0.5453	0.5415
iyileştirme	64x128 mel	kanallar 32x64x128, dropout 0.3, lr 0.002, batch 32	287654	15	0.5409	0.5364
arama	64x128 mel	kanallar 32x64x128, dropout 0.5, lr 0.0003, batch 32	287654	22	0.5348	0.5350
arama	80x128 mel	kanallar 32x64x128, dropout 0.3, lr 0.0003, batch 32	287654	14	0.5366	0.5298
iyileştirme	64x128 mel	kanallar 16x32x64, dropout 0.3, lr 0.001, batch 32	72406	16	0.5296	0.5284
iyileştirme	64x128 mel	kanallar 32x64x128, dropout 0.3, lr 0.001, batch 64	287654	14	0.5348	0.5244
arama	64x96 mel	kanallar 32x64x128, dropout 0.3, lr 0.0003, batch 32	287654	11	0.5314	0.5204

Kazanan yapılandırma: 64x128 mel; kanallar 32x64x128, dropout 0.3, lr 0.001, batch 16; 287,654 öğrenilebilir parametre; en iyi epoch 29.

CNN winner learning curve




Kazanan adayın eğitim/geçerleme kaybı ve macro-F1 eğrileri; erken durdurma geçerleme macro-F1 üzerinden yapıldı.

Kazanan modelin geerleme ve test sonuları.

Küme	Doğruluk	Dengeli doğruluk	Macro-F1	Ağırlıklı F1
Geerleme	0.5575	0.5604	0.5531	0.5518
Test	0.6264	0.6281	0.6282	0.6256

Test kümesinde sınıf bazında sonular.

Duygu	Örnek	Kesinlik	Duyarlılık	F1
Kızgın	181	0.7314	0.7072	0.7191
Tiksinti	181	0.6937	0.4254	0.5274
Korku	181	0.5045	0.6243	0.5580
Mutlu	181	0.6089	0.6022	0.6056
Nötr	155	0.7770	0.6968	0.7347
Üzgün	181	0.5560	0.7127	0.6247



Test kümesi karışıklık matrisi (satır bazında normalize).

Yöntem 2: Aralık Öznitelik Serisi + LSTM/GRU

Her kayıt, sayısı ve genişliği hiperparametre olan eşit aralıklı pencerelere bölündü; her aralıktan MFCC ortalama/std, delta-MFCC, RMS enerji, sıfır geçiş oranı ve spektral centroid/rolloff istatistikleri çıkarılarak sabit uzunlukta bir öznitelik serisi elde edildi [6, 9]. Seri, sıfırdan eğitilen LSTM/GRU tabanlı bir ağa verildi; zaman boyutu son adım/ortalama/maksimum/dikkat havuzlamasıyla özetlendi [6, 7].

Geçerleme kümesinde 16 aday tarandı; ardından kazanan etrafında 9 adaylık yerel iyileştirme turu koşuldu. Seçim ölçütü geçerleme macro-F1 değeridir; test kümesine yalnızca nihai kazanan dokundu.

Geçerleme macro-F1 sırasına göre ilk 12 aday (toplam 25 deneme).


Aşama	Öznitelik	Model	Parametre	En iyi epoch	Geçerleme doğruluk	Geçerleme macro-F1
iyileştirme	32 aralık x 200 ms	GRU, gizli 192, 2 katman, çift yönlü, mean havuz, lr 0.001, batch 64	942342	9	0.5636	0.5638
iyileştirme	24 aralık x 200 ms	GRU, gizli 192, 2 katman, çift yönlü, mean havuz, lr 0.001, batch 64	942342	9	0.5618	0.5619
iyileştirme	24 aralık x 200 ms	GRU, gizli 192, 2 katman, çift yönlü, mean havuz, lr 0.001, batch 64	942342	11	0.5671	0.5613
arama	24 aralık x 200 ms	GRU, gizli 192, 2 katman, çift yönlü, mean havuz, lr 0.001, batch 64	942342	10	0.5662	0.5612
arama	32 aralık x 300 ms	GRU, gizli 192, 2 katman, çift yönlü, mean havuz, lr 0.001, batch 64	942342	14	0.5601	0.5599
iyileştirme	24 aralık x 200 ms	GRU, gizli 384, 2 katman, çift yönlü, mean havuz, lr 0.001, batch 64	3654150	9	0.5584	0.5564
arama	24 aralık x 300 ms	GRU, gizli 192, 2 katman, çift yönlü, mean havuz, lr 0.001, batch 64	942342	11	0.5592	0.5535
arama	24 aralık x 300 ms	GRU, gizli 192, 2 katman, çift yönlü, mean havuz, lr 0.0003, batch 64	942342	14	0.5514	0.5506
iyileştirme	24 aralık x 200 ms	GRU, gizli 192, 2 katman, çift yönlü, mean havuz, lr 0.0005, batch 64	942342	12	0.5557	0.5498
iyileştirme	24 aralık x 200 ms	LSTM, gizli 192, 2 katman, çift yönlü, mean havuz, lr 0.001, batch 64	1255686	9	0.5514	0.5476
arama	24 aralık x 300 ms	GRU, gizli 96, 2 katman, çift yönlü, mean havuz, lr 0.001, batch 64	249990	9	0.5488	0.5467

Aşama	Öznitelik	Model	Parametre	En iyi epoch	Geçerleme doğruluk	Geçerleme macro-F1
arama	24 aralık x 300 ms	GRU, gizli 192, 2 katman, çift yönlü, max havuz, lr 0.001, batch 64	942342	9	0.5514	0.5466

Aynı model altında aralık düzeni hiperparametrelerinin etkisi.

Aralık sayısı	Aralık genişliği (ms)	Geçerleme macro-F1
16	300	0.5400
24	200	0.5612
24	300	0.5451
24	400	0.5376
32	300	0.5599

Kazanan yapılandırma: 32 aralık x 200 ms; GRU, gizli 192, 2 katman, çift yönlü, mean havuz, lr 0.001, batch 64; 942,342 öğrenilebilir parametre; en iyi epoch 9.



Kazanan adayın eğitim/geçerleme kaybı ve macro-F1 eğrileri; erken durdurma geçerleme macro-F1 üzerinden yapıldı.


Kazanan modelin geçerleme ve test sonuçları.

Küme	Doğruluk	Dengeli doğruluk	Macro-F1	Ağırlıklı F1
Geçerleme	0.5636	0.5673	0.5638	0.5615
Test	0.6377	0.6381	0.6440	0.6426

Test kümesinde sınıf bazında sonuçlar.

Duygu	Örnek	Kesinlik	Duyarlılık	F1
Kızgın	181	0.8357	0.6464	0.7290
Tiksinti	181	0.6453	0.6133	0.6289
Korku	181	0.4880	0.6740	0.5661

Duygu	Örnek	Kesinlik	Duyarlılık	F1
Mutlu	181	0.6243	0.6243	0.6243
Nötr	155	0.7652	0.6516	0.7038
Üzgün	181	0.6054	0.6188	0.6120



Test kümesi karışıklık matrisi (satır bazında normalize).

Geliştirme Aşaması

Hiperparametre optimizasyonunun ardından, literatürün önerdiği ve önceden eğitilmiş model gerektirmeyen geliştirmeler denendi: CNN için SpecAugment tarzı zaman/frekans maskeleme [10], LSTM/GRU için dikkat havuzlaması [6] ve öznitelik gürültüsü. Artırmalar yalnızca eğitim yığınlarına uygulandı; geçerleme ve test dokunulmadan bırakıldı.

Yöntem 1: Log-Mel Spectrogram + CNN — geliştirme denemeleri (taban 0.5531).

Varyant	Geçerleme macro-F1	Kazanana göre fark
SpecAugment maskeleme	0.5606	+0.0075
SpecAugment (hafif)	0.5453	-0.0078

En iyi varyant (SpecAugment maskeleye) geçerlemede kazananı geçtiği için test kümesinde de değerlendirildi: doğruluk 0.6292, macro-F1 0.6301.

Yöntem 2: Aralık Öznitelik Serisi + LSTM/GRU — geliştirme denemeleri (taban 0.5638).

Varyant	Geçerleme macro-F1	Kazanana göre fark
Dikkat (attention) havuzlama	0.5542	-0.0096
Öznitelik gürültüsü (std=0,1)	0.5602	-0.0036
Dikkat + gürültü	0.5597	-0.0041

Yöntem 2: Aralık Öznitelik Serisi + LSTM/GRU için hiçbir varyant geçerlemede kazananı geçemedi; test tekrarı yapılmadı.

Yöntemlerin Karşılaştırılması

Final yöntemleri ve önceki aşama sonuçları.

Model	Kaynak	Geçerleme macro-F1	Test doğruluk	Test dengeli doğruluk	Test macro-F1	Test ağırlıklı F1
Yöntem 1: Mel + CNN	Final	0.5531	0.6264	0.6281	0.6282	0.6256
Yöntem 2: Aralık + LSTM/GRU	Final	0.5638	0.6377	0.6381	0.6440	0.6426
MLP (mel vektörü)	Ödev 3 (alt küme)	0.4845	0.4424	0.4416	0.4299	0.4283
Gradient Boosting	Ödev 2 (alt küme)	-	0.5202	0.5179	0.5144	0.5153
Rastgele Orman	Ödev 2 (alt küme)	-	0.4860	0.4840	0.4721	0.4717

Yöntem 2: Aralık Öznitelik Serisi + LSTM/GRU test kümesinde 0.6377 doğruluk / 0.6440 macro-F1 ile Yöntem 1: Log-Mel Spectrogram + CNN yöntemini 1.1 puan geride bıraktı. Bu sıralama, CNN tabanlı yöntemlerin genellikle önde olduğu literatür eğiliminin [5, 8] hafifçe tersidir ve iki etkene bağlanabilir: aralık sayısı/genişliğinin hiperparametre olarak aranması, seriyi CREMA-D kayıtlarının süresine uygun çözünürlüğe getirdi; çerçeve-düzeyi akustik istatistikler üzerinde çift yönlü tekrarlayan ağların rekabetçi olduğu da bilinmektedir [6, 7]. Konuşmacı-bağımsız CREMA-D protokolünde sıfırdan eğitilen modeller için %55-65 bandı güçlü kabul edilir; insanların yalnız sesten tanıma başarısının %40,9 olduğu [1] ve önceden eğitilmiş büyük modellerin bile 62-77 UA bandında kaldığı [11] dikkate alınmalıdır. Önceki ödev satırları yaklaşık 2,6 bin kayıtlık alt kümede koşulduğundan doğrudan değil yön göstermek amacıyla verilmiştir; final modelleri hem tam veriyle hem de daha güçlü mimarilerle bu sonuçların belirgin üzerindedir.

Kararlılık Analizi (çoklu bölme)

Kararlılık analizi: Aynı deney akışı, üç ek konuşmacı bölümüyle (seed 7, 21, 99) baştan koşulmuştur. Yöntem 2 test doğruluğu bölmeye göre 0,5653 ile 0,6377 arasında değişmekte olup dört bölmenin ortalaması yaklaşık 0,589'dur. Resmî protokol bölümü (seed 42) bu aralığın üst ucundadır; bu nedenle sonuçlar tek bölmenin sayısı ile değil dağılımıyla birlikte raporlanmıştır. Tüm bölmelerde performans, insanların yalnız sesten ulaştığı %40,9 düzeyinin belirgin üzerindedir. Ek olarak, süreç-paralel bir otomasyonla 60 adaylık rastgele hiperparametre araması yürütülmüştür (aralık sayısı 16-48, genişlik 150-400 ms, gizli boyut 96-320, 1-3 katman). En iyi rastgele aday, seçili resmî yapılandırmanın kendisiyle örtüşmüş (geçerleme macro-F1 farkı +0,001) ve daha büyük modeller öne geçememiştir; bu, hem yapılandırma seçimini hem de "veri ölçeğine uygun model boyu" kararını bağımsız olarak doğrulamaktadır. Toplamda 178 model eğitilmiştir (43 sistematik aday, 60 rastgele aday, 4 bölme koşusu ve geliştirme varyantları).

Geliştirme: Pitch (F0) Özniteliği

Yöntem 2'nin aralık öznitelik serisine, tonlamanın taşıyıcısı olan temel frekans (F0) bilgisi eklenmiştir: aralık başına ortalama log-perde, perde standart sapması ve tonlu çerçeve oranı (öznitelik boyutu 44'ten 47'ye). Perde, duygusal ifadenin en güçlü akustik ipuçlarından biridir. Resmî bölmede (seed 42) bu ekleme, test doğruluğunu 0,6377'den 0,6566'ya, macro-F1'i 0,6440'tan 0,6619'a yükseltmiştir (iki bağımsız koşuda +2 ila +4 puan aralığında pozitif kazanç). Özellikle en zayıf sınıf olan tiksinti (disgust) F1'i belirgin biçimde iyileştirmiştir; bu, tiksinti sesinin karakteristik perde deseniyle tutarlıdır. librosa'nın pyin algoritması yalnızca öznitelik çıkarımı için kullanılmıştır (yönerge izinli); model hâlâ tamamen sıfırdan eğitilmektedir.

Yöntem 2 (BiGRU) — dört farklı konuşmacı bölümünde test sonuçları.

Bölme	Test doğruluk	Test macro-F1
seed 42 (resmî)	0.6377	0.6440
seed 7	0.5854	0.5835
seed 21	0.5666	0.5671
seed 99	0.5653	0.5661
Ortalama	0.5888	0.5902

MELD Üzerinde Genelleme

Aynı iki yöntem, hiçbir kod değişikliği olmadan MELD üzerinde de koşuldu (yalnızca ortak altı sınıfa düşen kayıtlar; konuşmacı-bağımsız bölme). MELD, dizi diyaloglarından geldiği için arka plan gürültüsü, gülüşmeler ve çok kısa kayıtlar içerir; ses-tek-kipli MELD sonuçlarının CREMA-D gibi stüdyo kayıtlarından belirgin düşük olması literatürde de beklenen durumdur [11]. Bu bölüm, yöntemlerin farklı kayıt koşullarına genellenebilirliğini göstermek için verilmiştir.

MELD (ortak 6 sınıf, konuşmacı-bağımsız) sonuçları.

Model	Geçerleme macro-F1	Test doğruluk	Test dengeli doğruluk	Test macro-F1
-------	--------------------	---------------	-----------------------	---------------

Model	Geçerleme macro-F1	Test doğruluk	Test dengeli doğruluk	Test macro-F1
Yöntem 1: Log-Mel Spectrogram + CNN	0.3111	0.4431	0.2303	0.2184
Yöntem 2: Aralık Öznitelik Serisi + LSTM/GRU	0.2633	0.3842	0.2036	0.1967

Ham doğruluk ile dengeli doğruluk arasındaki büyük fark, MELD'de nötr sınıfın baskınlığından kaynaklanır: ağırlıklı hata fonksiyonuna rağmen modeller azınlık duyguları güvenilir biçimde ayıramamaktadır. Bu, ses-tek-kipli MELD için literatürde bilinen bir sınırlılıktır ve metin/görüntü kiplerinin neden sıkça eklendiğini açıklar [11].

Hata Analizi

Yöntem 1: Log-Mel Spectrogram + CNN için en belirgin karışmalar: Korku kayıtlarının %24.9'i Üzgün olarak tahmin edildi; Mutlu kayıtlarının %20.4'i Korku olarak tahmin edildi. Bu örtüşme, benzer uyarılma düzeyindeki duyguların akustik olarak ayrışmasının zor olduğu yönündeki literatür gözlemleriyle tutarlıdır [6].

Yöntem 2: Aralık Öznitelik Serisi + LSTM/GRU için en belirgin karışmalar: Mutlu kayıtlarının %21.5'i Korku olarak tahmin edildi; Korku kayıtlarının %20.4'i Üzgün olarak tahmin edildi. Bu örtüşme, benzer uyarılma düzeyindeki duyguların akustik olarak ayrışmasının zor olduğu yönündeki literatür gözlemleriyle tutarlıdır [6].

Sonuç

Ödevin istediği iki yöntem de sıfırdan eğitilerek aynı konuşmacı-bağımsız protokolde karşılaştırıldı. Erken durdurma, sınıf-ağırlıklı hata fonksiyonu, geçerleme temelli hiperparametre optimizasyonu ve geliştirme aşaması ödev yönergesindeki akışı birebir izler. Yönergedeki "aktarmalı öğrenmede erken durdurmadan önce birkaç tur freeze ile eğitim" notu bu projede uygulanabilir değildir: ses kategorisinde aktarmalı öğrenme ve hazır model yasak olduğundan her iki model de sıfırdan eğitilmiş, erken durdurma doğrudan uygulanmıştır. Her iki yöntemin sonuçları da aynı kısıtlarla çalışan yayınların bildirdiği aralıkların içindedir [4, 5, 6, 8] ve aradaki fark, yöntem seçiminden çok veri protokolünün belirleyici olduğunu gösterecek kadar küçüktür.

Kaynakça

- [1] Cao vd. (2014). CREMA-D: Crowd-sourced Emotional Multimodal Actors Dataset. IEEE Trans. Affective Computing 5(4):377-390.
- [2] Satt, Rozenberg, Hoory (2017). Efficient Emotion Recognition from Speech Using Deep Learning on Spectrograms. Interspeech 2017.

- [3] Etienne vd. (2018). CNN+LSTM Architecture for Speech Emotion Recognition with Data Augmentation. arXiv:1802.05630.
- [4] Ristea, Ionescu (2021). Self-Paced Ensemble Learning for Speech and Audio Classification. Interspeech 2021 (CREMA-D 6 sınıf %68,12).
- [5] Evaluating raw waveforms with deep learning frameworks for speech emotion recognition (2023). arXiv:2307.02820.
- [6] Mirsamadi, Barsoum, Zhang (2017). Automatic speech emotion recognition using recurrent neural networks with local attention. ICASSP 2017.
- [7] Lee, Tashev (2015). High-level feature representation using recurrent neural network for speech emotion recognition. Interspeech 2015.
- [8] Kesim, Helli, Cavsak (2023). A Comparison of Time-based Models for Multimodal Emotion Recognition. arXiv:2306.13076.
- [9] Eyben vd. (2016). The Geneva Minimalistic Acoustic Parameter Set (GeMAPS) for Voice Research and Affective Computing. IEEE TAFRC 7(2).
- [10] Park vd. (2019). SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition. Interspeech 2019.
- [11] Ma vd. (2024). EmoBox: Multilingual Multi-corpus Speech Emotion Recognition Toolkit and Benchmark. Interspeech 2024.
- [12] Speech emotion recognition with light weight deep neural ensemble model using hand crafted features. Scientific Reports (2025). Rastgele bölme rejiminin şişirdiği sonuçlara örnek olarak anılmıştır.