

Sunum Konuşma Metni — 20 Dakika, Doğal Akış

Toplam plan: ~17 dk konuşma + ~3 dk canlı demo. Her kutu: [YAP] = sahne hareketi, altındaki paragraflar = ağzından çıkacak metin. Metinler **karar mantığını cümlelerin içinde** taşır — "neden böyle yaptım, başka türlü olsa ne olurdu" hep akışın parçası. Ezberleme; iki kez sesli oku, sonra kendi kelimelerle anlat. Kalın yazılan ifadeler vurgulaman gereken yerler.

1 Kapak

~25 sn

"Herkes merhaba, ben Ahmet Babagil. Bugün final projemi anlatacağım: konuşmadan duygu tanıma. Kısaca söylemek gerekirse, bilgisayara kısa bir ses kaydı veriyoruz ve bize o kişinin hangi duyguyla konuştuğunu söylemesini istiyoruz. Bunu yapmak için birbirinden tamamen farklı bakış açısına sahip iki sistem geliştirdim — biri sese bir resim gibi bakıyor, diğeri bir hikâye gibi — ve ikisini de aynı adil şartlarda yarıştırdım. Sunum boyunca sadece ne yaptığımı değil, **her adımda o kararı neden verdiğimi** de anlatmaya çalışacağım, çünkü bu projede asıl öğrendiğim şey kararların kendisiydi."

2 Bağlantılar

~15 sn

"Başlamadan şunu söyleyeyim: bu slayttaki bağlantılarda projenin tamamı var — orijinal veri seti, bütün kodum, deney çıktıları ve bu sunum. Bunu bilerek en başa koydum çünkü birazdan söyleyeceğim her sayının arkasında, isteyen herkesin gidip çalıştırabileceği kod var. Sonuçlarım tekrar üretilebilir; bu benim için projenin en önemli özelliklerinden biri."

3 Ajanda

~15 sn

"Akış şöyle olacak: önce problemi ve neden zor olduğunu anlatacağım, sonra veriyi nasıl hazırladığımı ve buradaki kritik kararımı. Ardından iki yöntemi tek tek açacağım, nasıl eğittiğimi ve 43 adaylık deney sürecini göstereceğim. Sonuçlara, sonuçların ne anlama geldiğine bakacağız ve en sonda sistemi canlı çalıştıracam."

4 Problem (ses düğmeleri)

~90 sn

[YAP] Önce konuş, sonra düğmelere tıkla: Kızgın → Üzgün → Mutlu. Her sesin bitmesini bekle.

"Problemi bir cümleyle tarif edeyim: elimizde iki-üç saniyelik bir konuşma kaydı var ve altı duygudan hangisiyle söylendiğini bulacağız — kızgın, tiksinti, korku, mutlu, nötr, üzgün. İlk bakışta 'metne bakarız, kelimelerden anlarız' diye düşünülebilir. Ama bu projede işin püf noktası tam tersi: **içerik değil, söyleyiş**. Size bunu anlatmak yerine dinletyim — çünkü bir kez duyunca problemin doğası netleşiyor. Şimdi aynı aktörün, aynı cümleyi — 'It's eleven o'clock', yani sadece 'saat on bir' — farklı duygularla söyleyişini çalışıyorum."

[sesleri çal] "...Fark ettiniz mi? Kelimeler yüzde yüz aynı. Değişen tek şey tonlama, tempo, enerji. Demek ki kelimeleri işleyen hiçbir yaklaşım bu problemi çözemez; modelin sesin **müziğini** dinlemesi gerekiyor. Ben de bütün tasarımı buna göre kurdum: iki yöntemim de metne değil, sinyalin akustiğine bakıyor. Bir de baştan söylemem gereken önemli bir kural var: bu projede hazır ya da önceden eğitilmiş model kullanmak yasaktı. Yani internetten indirilen, milyonlarca saatle eğitilmiş bir modeli alıp uyarlamak yok — **iki sistemi de sıfırdan, kendi verimle eğittim**. Bu kural aslında projeyi daha öğretici yaptı, çünkü her kararı kendim vermek zorunda kaldım."

5 Neden Zor?

~60 sn

"Peki bu problem neden gerçekten zor — neden yıllardır çalışılıyor da hâlâ çözülmüş sayılmıyor? Çünkü hedefimiz olan 'duygu', fizikteki gibi ölçebileceğimiz bir büyüklük değil. Sıcaklığı termometreyle ölçersiniz ve herkes aynı değeri okur; ama bir ses kaydına 'bu ne kadar kızgın?' diye sorduğunuzda herkes farklı cevap verir. Tonlamayı yorumlamak **öznel** — kişinin kültürüne, gününe, hatta o anki ruh hâline göre değişiyor. Bunu en iyi anlatan şey, veri setinin kendi hikâyesi: bu kayıtların etiketleri tek bir uzman tarafından değil, yaklaşık iki bin dört yüz kişinin **oylamasıyla** belirlenmiş — çünkü tek kişiye güvenilemezdi. Ve bu insanlar bile her zaman anlaşılamamış."

"Alttaki kırmızı satır benim için bu projenin pusulası oldu: insanlar, görüntü olmadan yalnızca sesi dinlediklerinde **ancak yüzde 40,9** doğruluk tutturabiliyor. Bu sayıyı bilmek çok önemliydi çünkü beklentimi gerçekçi kurdu: yüzde 90'lık bir hedef koysaydım kendimi kandırmış olurdum — birazdan neden öyle sayıların sahte olduğunu da göstereceğim. Benim hedefim insan çizgisini anlamlı biçimde geçmekti."

6 Veri Kümesi: CREMA-D

~75 sn

[YAP] Üç kartı, sonra "nasıl oluşturuldu" akışını, en son kırmızı şeridi göster.

"Veri setim CREMA-D. Neden bunu seçtim? Üç sebebi var. Birincisi büyüklüğü: 7.442 kayıt, sıfırdan model eğitmek için yeterli ama yönetilebilir bir ölçek. İkincisi çeşitliliği: 91 farklı profesyonel aktör var — 48 erkek, 43 kadın — bu bana birazdan anlatacağım konuşmacı-bağımsız düzeni kurma imkânı verdi; daha az konuşmacılı bir setle bu mümkün olmazdı. Üçüncüsü de kontrollü yapısı: herkes aynı 12 cümleyi söylüyor, dolayısıyla **içerik sabitlenmiş, duygu izole edilmiş** durumda — az önce dinlettiğim örnek tam da bu tasarımın ürünü."

"Nasıl oluşturulduğuna da kısaca değineyim çünkü etiket kalitesi her şeyi belirliyor: aktörler stüdyoda her cümleyi altı duyguyla kaydetmiş; sonra bu kayıtlar internette binlerce değerlendiriciye dinletilip oylanmış. Yani etiketler tek kişinin kanaati değil, kalabalığın ortak kararı. Veriyi eğitim, geçerleme ve test olarak üçe böldüm — ve bölme şeklim, bu projede verdiğim **en kritik karar**. O kadar önemli ki bir sonraki slaytı sadece buna ayırdım."

7 Bölme Nasıl Yapıldı? (animasyon)

~75 sn

[YAP] Animasyon dönerken anlat; aktörlerin kutulara düşüşünü elinle takip et.

"Ekranı gördüğünüz şey şu: veriyi bölerken kayıtları değil, **aktörleri** dağıtıyorum. Bir aktör hangi kutuya düştüyse, o kişinin yedi bin küsur kayıt içindeki bütün kayıtları o kutuda kalıyor. Bunu neden yaptım? Şöyle düşünün: kayıtları rastgele bölseydim, aynı kişinin sesi hem eğitimde hem testte olacaktı. Model de şunu öğrenecekti: 'bu ses tınısını tanıyorum, bu adam genelde kızgın kayıtlarda vardı' — yani **duyguyu değil, kişiyi ezberleyecekti**. Test skoru harika görünecekti ama tamamen sahte olacaktı."

"Bu fark kağıt üstünde kalmıyor: literatürde rastgele bölmeyle rapor edilen sonuçlar, konuşmacı-bağımsız sonuçlardan 20-30 puan daha yüksek çıkıyor. İnternette gördüğünüz yüzde 90'lık, hatta 98'lik CREMA-D sonuçlarının neredeyse tamamı bu tuzağın ürünü. Ben zor olan yolu bilerek seçtim: test kümemdeki 13 aktörün sesini modelim eğitim boyunca **hiç duymadı**. Bu yüzden birazdan göstereceğim her sayı, gerçekten 'hiç tanımadığı insanlarda' ölçülmüş performanstır. Daha düşük görünür ama gerçektir — ve ben düşük-gerçeği, yüksek-sahteye tercih ettim."

8 Yönerge → Uygulama

~40 sn

"Yöntemlerimi seçerken yönergeden şaşmadım — bu slayt birebir eşleşmeyi gösteriyor. Yönerge birinci yöntem için 'mel spectrogram ile eğitilen CNN' diyor; ben 64'e 128'lik log-mel artı sıfırdan yazılmış bir CNN kurdum. İkinci yöntem için 'sesi aralıklara böl, aralık genişliği ve sayısı hiperparametre olsun, öznitelik serisini LSTM veya GRU'ya ver' diyor; ben de tam bunu yaptım ve o iki hiperparametreyi el yordamıyla değil, **sistematiik aramayla** belirledim — birazdan göreceksiniz, projenin kaderini de bu arama değiştirdi. Alttaki yeşil şerit özet: aktarmalı öğrenme yok, hazır model yok; erken durdurma ve ağırlıklı hata fonksiyonu, yönergenin istediği gibi, var."

9 Yöntem 1 — Log-Mel + CNN (akış animasyonu)

~80 sn

[YAP] Paneller sırayla yanarken anlat.

"Birinci yöntemin fikri şu: madem duygu sesin dokusunda saklı, o dokuyu **görünür hale getirip** bir görüntü işleme problemine çevirelim. Ekranda akışı görüyorsunuz: ses önce log-mel spectrogram'a dönüşüyor — birazdan bunu ayrıca göstereceğim — sonra bu 'resim', üç bloklu bir evrişimli ağdan geçiyor ve sonda altı duygunun olasılığı çıkıyor."

"Burada vermem gereken önemli bir karar ağın boyutuydu. Modern görüntü ağları milyonlarca parametrelili; benim ağım ise bilinçli olarak küçük: yaklaşık **300 bin parametre**. Neden? Çünkü elimde milyonlarca değil, 5.234 eğitim kaydı var. Daha derin bir ağ denemedim değil — denedim: aramada dört bloklu, 256 kanallı bir aday da vardı ve geçerlemede kazanamadı; küçültülmüş 16-32-64'lük aday da kazanamadı. Yani 'ne kadar büyük o kadar iyi' burada çalışmıyor; **veriye göre boy** gerekiyor, ve bu dengeyi tahminle değil deneyle buldum. Bir de sondaki 'global average pooling' tercihim var: klasik yöntemle tüm haritayı düzleştirip dev bir katmana bağlasaydım parametre sayısı patlayacak, ezber riski büyüyecekti; ortalama almak hem ağı küçük tutuyor hem de kayıt uzunluğu değişse bile çalışmasını sağlıyor."

10 Sesin Resme Dönüşümü (animasyon)

~50 sn

"Bu dönüşümün kendisi de bir tasarım kararı, o yüzden ayrıca göstermek istedim. Sarı pencere sesin üzerinde kayıyor; her durduğunda 'şu anda hangi frekanslar ne kadar güçlü?' diye ölçüyoruz ve haritaya bir sütun ekliyoruz. Peki neden ham dalgayı direkt vermedim de bu haritaya çevirdim? Çünkü ham dalga saniyede 16 bin sayı demek ve duygu bilgisi orada çok dağınık; ağın bunu kendi başına çözmesi için çok daha fazla veri gerekirdi. Mel dönüşümü ise **insan kulağının ölçeğini** kullanıyor — kulağımız pes seslerdeki farklara duyarlı, tizlerde duyarsızdır; mel ölçeği filtreleri tam bu duyarlılığa göre yerleştirir. Yani ağa, kulağın milyonlarca yıllık ön işlemlerini hazır veriyorum ve o sınırlı verisini asıl işe, duygu desenlerini bulmaya harcıyor. Çözünürlüğü de aramaya dahil ettim bu arada: 80 bantlı daha ince bir varyantı da denedim, geçerlemede 64'ü geçemedi — demek ki bu problemde 64 bant yeterli bilgiyi taşıyor."

11 Konvolüsyon (animasyon)

~40 sn

"CNN'in içinde ne döndüğünü de somutlaştırayım — çünkü 'derin öğrenme' deyince kara kutu sanılıyor, oysa çekirdek işlem bu kadar basit: küçük bir filtre resmin üzerinde geziyor, her konumda çarpıp topluyor, tek sayı yazıyor. Bu filtre bir **desen dedektörü** — kenar, bant, enerji sıçraması gibi şeyleri arıyor. Kritik nokta şu: bu filtrenin içindeki sayıları ben yazmıyorum; **eğitim kendisi öğreniyor**. Yani hangi ses deseninin kızgınlığa işaret ettiğini ben söylemiyorum, model veriden çıkarıyor. Elle kural yazsaydım — 'yüksek enerji kızgındır' gibi — az önce dinlediğiniz mutlu örneği de kızgın sanırdı; öğrenilen filtreler bu inceliği yakalayabiliyor."

12 MaxPool (animasyon)

~25 sn

"Bloklar arasında bir de özetleme adımı var: her bölgeden yalnızca en güçlü değeri alıyorum. İki şey kazandırıyor: harita küçüldükçe hesap azalıyor, ve daha önemlisi model 'desen tam olarak hangi milisaniyedeydi' takıntısından kurtuluyor — duygu için desenin varlığı önemli, pikseli değil. Bunu yapmasaydım ağ hem hantal hem de kayıttaki ufak kaymalara aşırı hassas olurdu."

13 Yöntem 2 — Aralık Serisi + BiGRU (akış animasyonu)

~90 sn

"İkinci yöntemde bilinçli olarak zıt bir bakış denedim. Birinci yöntem sese tek bir bütün resim gibi bakıyordu; ama duygu aslında zamanda **gelişen** bir şey — öfke cümlesinin sonunda patlar, üzüntü baştan sona sönük gider. Bu gelişimi yakalamak için sesi kronolojik bir hikâyeye çevirdim: kaydı eşit yerleşimli aralıklara bölüyorum ve her aralıktan 44 tane akustik özellik çıkarıyorum — tınıyı özetleyen MFCC katsayıları, enerji, sesin parlaklığını anlatan spektral ölçüler. Bu özellikleri seçerken de keyfi davranmadım; konuşma işleme literatürünün onlarca yıldır kullandığı standart kümeyi aldım, çünkü tekerleği yeniden icat etmek yerine gücümü asıl soruya saklamak istedim."

"Asıl soru da şuydu: **kaç aralık, ne genişlikte?** Yönerge bunu hiperparametre yapmamı istiyordu ve iyi ki istemiş. Az aralık kullansaydım — mesela 16 — zaman çözünürlüğü kabalaşacak, duygunun iniş çıkışları tek karede ezilecekti; nitekim 16'lık aday aramada geride kaldı. Pencereyi çok geniş tutsaydım — 400 milisaniye denedim — farklı duygu evreleri aynı pencereye karışacaktı; o da kazanamadı. Arama sonunda **32 aralık çarpı 200 milisaniye** öne çıktı ve bu seçim, birazdan göreceğiniz gibi, yarışmanın kaderini belirledi. Seriyi okuyan ağ da çift yönlü bir GRU: kaydı hem baştan sona hem sondan başa okuyor. Tek yönlü varyantı da denedim — kaybetti; mantıklı, çünkü bir anın anlamı hem öncesine hem sonrasına bağlı. LSTM ile GRU arasında da dogmatik seçmedim, ikisini de yarıştırdım: GRU, daha az parametreyle aynı işi gördüğü için geçerlemede önde bitirdi."

14 Aralık Pencereleeri (animasyon)

~30 sn

"Pencerelerin yerleşimini de göstereyim çünkü ince ama önemli bir detay var: kayıtlarım ortalama iki buçuk saniye, ama 32 çarpı 200 milisaniye 6,4 saniye ediyor — yani pencereler **örtüşüyor**, kayan bir mercek gibi. Bunu bilerek böyle bıraktım: örtüşme sayesinde hiçbir geçiş anı iki pencerenin arasında kaybolmuyor. Ve kayıt uzun da olsa kısa da olsa her zaman tam 32 adımlık bir seri çıkıyor — bu sabitlik sayesinde ağ, değişken uzunluk derdiyle hiç uğraşmıyor."

15 GRU — Not Defteri (animasyon)

~45 sn

"GRU'nun ne yaptığını şöyle anlatayım: kitap okurken not defteri tutan biri düşünün. Her aralığı okuyor ve yeşil defterini güncelliyor. Buradaki zarif kısım **z kapısı**: her adımda 'defterin ne kadarını yeni bilgiyle değiştireyim, ne kadarını koruyayım?' kararını veriyor — ve bu kararı da eğitim öğreniyor. Neden düz bir ağ değil de bu kapılı yapı? Çünkü düz tekrarlayan ağlar uzun serilerde unuttandır; serinin başındaki bilgi sona ulaşamaz. Kapılar tam bu unutkanlığı çözmek için var. Serinin sonunda defter, kaydın tamamının özeti oluyor; ben de sınıflandırmayı adımların ortalamasından yaptım — sadece son adıma baksaydım kaydın başındaki ipuçlarını çöpe atmış olurdum, denedim de: 'son adım' varyantı ortalamanın gerisinde kaldı."

16 Eğitim Protokolü

~70 sn

"İki modeli de tamamen aynı disiplinle eğittim ki karşılaştırma adil olsun — farklı özen gösterseydim kazananın mimariden mi özenden mi kazandığı belirsiz kalırdı. Sol taraf teknik tercihler: AdamW eniyileyici, sınıf ağırlıklı hata fonksiyonu, erken durdurma, gradyan kırpması. Sağ taraf ise bu projede en çok önemseydiğim kısım, dürüstlük önlemleri. Normalizasyon parametrelerini — yani öznitelikleri ortak ölçeğe çeken ortalama ve sapmayı — **yalnızca eğitim verisinden** hesapladım. Neden bu kadar kritik? Test verisinin ortalamasını da katsaydım, testin bilgisi eğitime sızacaktı; bu, küçük ama sinsî bir kopya çekme biçimidir ve literatürdeki şişkin sonuçların bir kısmı buradan gelir."

"Aynı mantıkla, bütün ayar kararlarını geçerleme kümesinde verdim ve test kümesine yöntem başına **yalnızca bir kez**, en sonda dokundum. Teste bakarak ayar yapsaydım test artık 'görülmemiş veri' olmaktan çıkardı — deneme sınavına çalışıp deneme sınavıyla övünmek gibi. Toplamda 43 aday eğittim ve sabit tohum kullandığım için bu 43 deneyin her biri bugün yeniden koşulsa aynı sonucu verir."

17 Eğitim Döngüsü (animasyon)

~35 sn

"Eğitimin kendisi bu dönen çark: 32 kayıtlık bir yığın geliyor, model tahmin ediyor, ne kadar yanlışlığı ölçülüyor, hata geriye doğru izlenip her ağırlığın payı bulunuyor ve hepsi minicik düzeltiliyor. Neden 32'lik yığınlar da tek tek değil? Tek tek gitseydim her adım gürültülü olurdu ve eğitim sürünürdü; tüm veriyi tek seferde verseydim de bellek yetmezdi ve model incelikleri kaçırdı. 32-64 arası, bu dengenin tatlı noktası — ve evet, bunu da aramaya dahil ettim."

18 Ağırlıklı Loss (animasyon)

~40 sn

"Şimdi küçük görünen ama prensipli bir karar: sınıflarım tam dengeli değil — nötrün 1.087 kaydı var, diğerlerinin 1.271'er. Fark küçük, 'boş ver' denebilirdi. Ama hata fonksiyonunu sınıf sayısı ile ters orantılı ağırlıklandırdım: formül ekranda, pratik sonucu şu — nötr bir kaydı yanlış yapmak, modele yüzde 17 daha pahalıya patlıyor. Bunu yapmasaydım ne olurdu? Model, çoğunluğa oynamanın kârlı olduğunu keşfedecekti. Bu veri setinde etkisi küçük olurdu belki; ama birazdan MELD'de göreceksiniz — dengesizlik büyüyünce bu önlem olmadan model tamamen tek sınıfa kaçıyor. Yani bu, 'burada şart mıydı'dan öte, **doğru alışkanlık** kararıydı; yönergenin de açık şartıydı."

19 Softmax (animasyon)

~25 sn

"Modelin son adımı softmax: ağırlık ürettiği ham puanları, toplamı yüzde yüz olan olasılıklara çeviriyor. Kaydırdıkça görüyorsunuz — bir sınıfın puanı artınca payı büyüyor, diğerlerininki mecburen küçülüyor. Bunu istememin sebebi sadece 'en büyüğü seç' değil: olasılık görmek, modelin **ne kadar emin** olduğunu da söylüyor. Demoda göreceksiniz; model yanlışladığında genelde olasılıklar da kararsız — bu, sistemin dürüst bir sinyali."

20 43 Adayın Yarışı (gerçek veri)

~70 sn

"Bu grafik temsili değil; **gerçek deney kayıtlarımdan** üretildi. Her çubuk eğittiğim bir aday: maviler CNN ailesi, turuncular GRU ailesi; yeşil kesikli çizgi o anki lideri izliyor. Aramayı iki kademeli kurdum ve bunun bir mantığı var: önce geniş bir tarama — ama rastgele değil, **her adayda tek bir ayarı değiştirerek**. Neden? Çünkü beş ayarı birden değiştirseydim, sonuç değiştiğinde hangisinin etkisi olduğunu asla bilemeyecektim; tek-değişken tasarımda her denemeden bir ders çıkıyor. Sonra ikinci kademe: kazananın çevresinde ince ayar turu — iyi bir bölge bulduysan, en iyisi muhtemelen hemen yakınındadır."

"Ve işte projenin dönüm noktası: ilk taramada CNN öndeydi. Ama ikinci turda, GRU'nun aralık düzenini 24'e 300'den **32'ye 200'e** çektiğim aday geldi ve liderliği aldı. Buradan çıkardığım ders sunumun ana mesajlarından biri: **kazananı mimari değil, hiperparametre araması belirledi**. Aynı GRU, kötü aralık düzeniyle sıradan bir modeldi; doğru düzenle şampiyon oldu."

21 SONUÇLAR

~70 sn

[YAP] Kartları sırayla göster, yavaş konuş — vitrin slaytı.

"Gelelim sonuçlara. Test kümesinde — yani modelin sesini hiç duymadığı 13 aktörün 1.060 kaydında — CNN **yüzde 62,6** aldı. Veri artırmayla, birazdan anlatacağım SpecAugment'la, 62,9'a çıktı. Kazanan ise **BiGRU: yüzde 63,8 doğruluk ve 0,644 macro-F1**. Grafikte üç ayrı metrikte de aynı sıralamayı görüyorsunuz — sıralama metrik seçimine bağlı değil, bu önemli."

"Bu sayılar iyi mi? Bağlamsız sayı bir şey söylemez, o yüzden çıpalarımı vereyim: rastgele tahmin yüzde 17'de kalır; insanlar 41'de; sıfırdan eğitilmiş modeller için literatürdeki en iyi yayınlanmış sonuç 68 — ve o bile beş modelin birleşimiyle alınmış. Ben tek modelle o tavana 4 puan mesafedeyim ve insan performansının 22 puan üzerindeyim. İki yöntem arasındaki 1,2 puanlık farkı da abartmıyorum; bana kalırsa asıl bulgu şu: **iki farklı temsil de doğru protokolle eğitilince benzer tavana geliyor** — belirleyici olan yöntemden çok, sürecin doğru kurulması."

YENİ Kararlılık — Dört Farklı Bölme (sunumda 22. slayt; sonraki numaralar bir kayar)

~45 sn

"Bu slayt sunumun en taze bulgusu — bu deneyi dün bizzat koştum. Aklıma şu soru takıldı: '63,8 aldık ama ya bu, şanslı bir bölmenin eseriye?' Cevabı tahminle değil deneyle verdim: aynı arama ve iyileştirme akışını, üç farklı konuşmacı dağılımıyla baştan koşturdum. Sonuç ekranda: doğruluk bölmeye göre **%56,5 ile %63,8 arasında** değişiyor, ortalama **%59** civarı. Yani resmî bölmemiz aralığın şanslı ucundaymış — bunu saklamıyorum, tam tersine raporluyorum; çünkü tek bir sayıya değil **dağılıma** güvenmek gerektiğini bu deney bana canlı gösterdi. Ve önemli olan şu: en kötü bölmede bile insan performansının 15 puandan fazla üzerindeyiz. Bir adım daha ileri gittim: kendi yazdığım otomasyonla, çok daha geniş bir uzayda **60 adaylık rastgele arama** koşturdum — 48 aralığa, üç katmanlı, 320 birimlik büyük modellere kadar. Sonuç öğreticiydi: en iyi aday, bizim resmî yapılandırmamızın ta kendisiydi; fark binde bir, yani gürültü. Büyük modeller kazanamadı. Toplamda **178 model eğittim** ve hepsinin kaydı deney defterimde duruyor."

22 Öğrenme Eğrileri

~35 sn

"Bu grafikler eğitimin dürüst fotoğrafı ve bir kararımın da kanıtı. Mavi çizgi, eğitim hatası: sürekli düşüyor — model çalıştığı sorularda durmadan iyileşiyor. Ama turuncu çizgiye bakın: geçerleme hatası bir yerde dönüyor ve yükselmeye başlıyor. O dönüş anı, **ezberin başladığı an**. Eğitime devam etseydim eğitim skoru yüzde doksanlara çıkacaktı — kağıt üstünde muhteşem, gerçekte işe yaramaz. Modeli tam dönüş noktasında seçmemin sebebi bu."

23 Early Stopping (animasyon)

~35 sn

"Bunu elle takip etmedim tabii; mekanizması otomatik ve burada canlı görüyorsunuz. Her turda geçerleme puanı ölçülüyor; en iyi anın ağırlıkları kenarda saklanıyor; üst üste sekiz tur iyileşme gelmezse eğitim duruyor ve yıldızla işaretli en iyi an geri yükleniyor. Sabrı neden sekiz seçtim? Daha kısa tutsaydım geçici bir dalgalanmada erken pes edecekti; çok uzun tutsaydım boşa eğitimle vakit yakacaktı. Somut örnek: CNN'im 37 tur koştu ama teslim ettiğim model **29'uncu turun** modeli — sonraki sekiz turun hepsi ezberdi."

24 Matris Nasıl Dolar? (animasyon)

~25 sn

"Sonuçları tek sayıya indirmek istemedim; nerede iyi, nerede kötü olduğumu görmem gerekiyordu. Bunun aracı karışıklık matrisi — ve nasıl çalıştığını burada izleyebilirsiniz: her test kaydı, gerçek etiketi ile tahminin kesiştiği hücreye düşüyor. Köşegene düşenler doğrular; dışarı taşanlar ise bana 'model şunu şununla karıştırıyor' diye adres veriyor."

25 Karışıklık Matrisleri (gerçek)

~45 sn

"İşte iki modelin gerçek matrisleri. İlk bakışta iki şey görüyorum. Birincisi sevindirici: köşegen 0,61 ile 0,67 arasında — yani başarı altı sınıfa **dengeli** dağılmış, model tek sınıfa kaçmamış; ağırlıklı hata fonksiyonu görevini yapmış. İkincisi öğretici: karışmaların deseni rastgele değil. Mutlu kayıtların bir kısmı korku sanılıyor, korku üzgünle karışıyor — ikisi de benzer enerji seviyesindeki duygular; akustik olarak gerçekten yakınlar, insanlar da bunları karıştırıyor. En zayıf sınıfım tiksinti: belirgin bir akustik imzası yok. Bunu saklamıyorum; tam tersine demoda bilerek göstereceğim, çünkü **modelin sınırını bilmek, başarısını bilmek kadar değerli.**"

26 %90 Tuzağı (animasyon)

~35 sn

"Sunum boyunca hep 'macro-F1' dedim; neden basit doğruluğa güvenmediğimi bu animasyon anlatıyor. Yüz örneğin doksanı A sınıfıysa, her şeye A diyen tembel bir model yüzde 90 doğruluk alır — etkileyici görünür ama B sınıfını hiç öğrenmemiştir; dengeli bakınca yüzde 50'dir, yazı-tura yani. Dengesiz veride doğruluk **yalan söyleyebilir**. Macro-F1 ise her sınıfa eşit söz hakkı verir; ben de bütün model seçimlerimi onunla yaptım. Bu seçimin gerçek hayattaki karşılığını bir sonraki bölümde, MELD'de göreceksiniz."

27 Geliştirme Aşaması

~60 sn

"Optimizasyon bittikten sonra yönergenin istediği geliştirme aşamasına geçtim ve iki tarafa da literatürün önerdiği birer fikir denedim. CNN tarafına SpecAugment: eğitim sırasında spectrogram'da rastgele şeritleri maskeliyorum. Mantığı şu: model, bilginin bir kısmı örtülüyken de doğru karar vermeyi öğrenirse ezberi kırılır — bantla kelimeleri kapatılmış metinden anlam çıkarmaya alışmak gibi. Geçerlemede kazandı, teste taşıdım: 62,9 oradan geldi."

"GRU tarafına da dikkat mekanizması ve gürültü ekleme denedim — ve ikisi de geçerlemede kazananı **geçemedi**. Burada verdiğim karar, bence projenin en prensipli anı: bu varyantları teste hiç götürmedim. Götürseydim ne olurdu? Belki testte şansa daha yüksek bir sayı çıkacaktı ve onu rapor etme cazibesi doğacaktı — ama o noktada test, seçim aracına dönüşür ve anlamını yitirir. Ben olumsuz sonucu da rapora yazdım; çünkü 'neyin işe yaramadığını bilmek' de bu deneyin bir çıktısı."

28 Genelleme: MELD

~50 sn

"Son bir soruyu kendime sormam gerekiyordu: bu sistem sadece bu veri setinde mi iyi? Bunu cevaplamak için aynı kodu, tek satır değiştirmeden, bambaşka bir dünyada çalıştırdım: MELD — bir dizinin gerçek diyalogları. Sonuçlar beklediğim gibi sert düştü: yüzde 44 ve 38. Ama bu düşüşün **nedenlerini** okumak asıl ders: arka planda gülüşmeler ve müzik var, kayıtlar bazen yarım saniye, konuşma doğal ve duygular yarı yarıya nötr. Ham doğruluk ile dengeli doğruluk arasındaki uçurum, az önce anlattığım tuzağın canlı örneği — model nötre kaçmaya çalışıyor. Çıkarımım şu: sınır benim yöntemlerimde değil, verinin koşullarında; nitekim literatür MELD'i sesle değil, ses artı metin artı görüntüyle çözmeye çalışıyor. Bunu koşmasaydım 'tek veri setine aşırı uyum' eleştirisine cevabım olmayacaktı; şimdi var."

29 Literatürde Neredeyiz?

~35 sn

[YAP] Noktaları soldan sağa göster, yeşilde dur.

"Her şeyi tek resme toplayayım. En solda şans: 17. Sonra insan kulağı: 41. Yeşil nokta biz: **63,8**. Sağımızda sıfırdan modellerin yayınlanmış tavanı: 68,1 — beş modelli bir birleşimle. En sağda, milyonlarca saat veriyle önceden eğitilmiş dev modeller bile bu problemde 77'yi geçemiyor — bu da problemin ne kadar çetin olduğunun bir başka kanıtı. Kısacası: insan çizgisinin belirgin üzerinde, kurallara uygun en iyi sonuçların hemen dibindeyiz — ve buraya tek modelle, sıfırdan geldik."

30 Sonuç

~40 sn

"Toparlıyorum. İki farklı bakış açısını — sese resim gibi bakan CNN'i ve hikâye gibi okuyan GRU'yu — sıfırdan eğitip aynı adil protokolde yarıştırdım. Kazananı mimari değil, sistematik hiperparametre araması belirledi; işe yaramayan fikirleri de sakladım değil, raporladım. Ve bütün bu sonuçlar, sabit tohum ve kayıtlı modeller sayesinde bugün yeniden üretilebilir durumda. Bir projeden alınabilecek en büyük dersi şöyle özetlerim: **doğru sonuç, doğru süreçten çıkar** — bölmeyi doğru yap, seçimi geçerlemede yap, teste bir kez dokun. Şimdi de sistemin gerçekten çalıştığını gösterme vakti."

31 Demo Akışı (animasyon)

~15 sn

"Az sonra göreceğiniz şeyin önizlemesi bu: klasörden kayıtlar seçilecek, iki yöntemden geçecek ve tahminler, olasılıklarıyla birlikte anında gelecek. Hadi canlısına geçelim." **[YAP] Alt+Tab → terminal → Enter. Demo senaryon: rastgele 3 → bir iyi örneği anlat → zor disgust örneğini adıyla çalıştır → 'modelin sınırı, matrizen biliyorduk'.**

32-33 Kaynaklar

~10 sn

"Dayandığım kaynaklar bunlar — veri setinin makalesinden, yöntemlerime şablon olan çalışmalara ve beklenti aralıklarını aldığım kıyaslamalara kadar. Sorularda herhangi birine girebilirim."

34 Teşekkürler

"Dinlediğiniz için çok teşekkür ederim. Sorularınızı memnuniyetle alayım."

Süre bütçesi (~17 dk konuşma + demo): Bölüm 1 (slayt 1-8) ≈ 6 dk • Yöntemler (9-15) ≈ 6 dk • Eğitim+arama (16-20) ≈ 4 dk • Sonuç bölümü (21-30) ≈ 6,5 dk... toplam taşarsa doğal kısaltma noktaları: 12 (MaxPool), 17 (döngü), 19 (softmax), 24 (matris dolumu) — bunlarda tek cümle söyleyip geç. Prova yapıp ölç; 20 dakikayı 1-2 dk altında bitirmek soru için nefes bırakır.

Doğallık notu: Bu metin okunmak için değil, İÇSELLEŞTİRİLMEK için. İki kez sesli oku; üçüncü turda slayta bakıp kendi kelimelerinle anlat. Takıldığında köprü cümleler hazır: "Buradaki kararın mantığı şuydu..." — bu kalıp seni her yerden kurtarır, çünkü her slaytın gerçekten bir karar mantığı var ve artık hepsini biliyorsun.