

YAP 470 / BİL 570 – Proje İlerleme Raporu 1

Grup 23 — Ahmet Babagil (211101067) · Konu: Konuşmadan Duygu Tanıma Bu aşamada model: **K-En Yakın Komşu (KNN)**. Akış: Wav2Vec2 (donmuş öznitelik çıkarıcı) → StandardScaler → PCA → KNN. İncelenen hiperparametreler: **F** (öznitelik vektör boyutu), **P** (PCA çıktı boyutu), **K** (komşu sayısı).

Not: ML iş akışında yalnızca **numpy / pandas / scikit-learn** kullanılmıştır. torch/transformers SADECE Wav2Vec2 öznitelik çıkarımı aşamasında kullanılır.

Erişim Bilgileri

Orijinal Veri Seti Adı: CREMA-D ve MELD (iki ayrı veri seti).

Orijinal Veri Seti Bağlantısı: - CREMA-D: <https://github.com/CheyneyComputerScience/CREMA-D> (ses, Hugging Face aynası [AbtractTTS/CREMA-D](https://huggingface.co/AbtractTTS/CREMA-D) ile indirildi — orijinal dosya adları korunur) - MELD: <https://github.com/declare-lab/MELD> (ham veri: <http://web.eecs.umich.edu/~mihalcea/downloads/MELD.Raw.tar.gz>)

Proje Çalışmasının Yüklendiği Google Drive Bağlantısı: [YÜKLENECEK — link buraya] Kod + git geçmişi: <https://github.com/AhmetBabagil/speech-emotion-recognition> (Link izin istemeden erişilebilir olacak şekilde public yapılacaktır.)

Veri seti boyutu notu: MELD ham verisi (~11 GB) Google Drive'a yüklenemeyecek kadar büyük olabilir. Bu durumda veri seti **USB ile ertesi gün** teslim edilecektir. (CREMA-D ~0.6 GB; MELD'ten çıkarılan 16 kHz ses ~ birkaç GB.)

Çalıştırılacak Dosyalar ve Ne Yaptıkları:

Dosya	Ne yapar
<code>scripts/download_data.py</code>	CREMA-D + MELD'i indirir; MELD videolarından sesi (ffmpeg) çıkarır
<code>scripts/build_manifest.py</code>	İki veri setini ortak 6 duyguda birleşik manifest'e (<code>data/processed/manifest.csv</code>) yazar
<code>odev1/extract.py</code>	Wav2Vec2 ile her klipten öznitelik çıkarır ve diske cache'ler (yavaş, bir kez)
<code>odev1/run_experiment.py</code>	KNN+PCA hiperparametre gridini iki veri setinde koşar; tablolar + karmaşıklık matrisi üretir

Sıra: `download_data.py` → `build_manifest.py` → `odev1/extract.py` → `odev1/run_experiment.py`.

Veri Seti ve Değerlendirme Metrikleri

Ortak sınıflar. İki veri setinin kesişimi olan 6 duygu kullanılır: `angry`, `disgust`, `fear`, `happy`, `neutral`, `sad`. (MELD'deki `surprise` ortak olmadığından atılır; CREMA-D'de zaten yoktur.) Toplam ~19.512 kayıt (CREMA-D 7.442 + MELD 12.070).

Eğitim / Geçerleme / Test oluşturma — denek-bağımsız (speaker-independent). Her veri seti **ayrı ayrı** bölünür ve bir **konuşmacı yalnızca tek bir kümede** yer alır (CREMA-D'de oyuncu kimliği, MELD'de konuşmacı adı). Bu, modelin duygu yerine sesi/konuşmacıyı ezberlemesini engeller. Konuşmacılar sabit tohumla (seed=42) karıştırılıp bölünür: **%70 eğitim / %15 geçerleme / %15 test** (konuşmacı bazında). Geçerleme kümesi hiperparametre (F, P, K) seçimi için; test kümesi yalnızca en iyi yapılandırmanın nihai ölçümü için kullanılır (test hiçbir seçimde kullanılmaz).

Değerlendirme metrikleri. Sınıflandırma problemi olduğundan: **doğruluk**, **dengeli doğruluk**, **makro-F1** (sınıf dengesizliği için), **ağırlıklı-F1** ve **karmaşıklık matrisi**. MELD sınıf dağılımı dengesiz (neutral baskın) olduğundan makro-F1 ve dengeli doğruluk öne çıkarılır. (Şablondaki MSE ve X=yıllık kazanç sütunları sırasıyla regresyon ve finans projeleri içindir; bu sınıflandırma görevine uygulanmaz.)

Yöntem

Öznitelik çıkarımı (PCA öncesi — ayrıntılı)

- Ses okuma.** Her kayıt 16 kHz, tek kanal (mono) olarak okunur (librosa). Çok uzun klipler en fazla **6 sn** olacak şekilde merkezden kırpılır; çok kısa olanlar Wav2Vec2'nin minimum girdi uzunluğuna ped'lenir.
- Normalizasyon.** Her kayıt kendi içinde sıfır-ortalama / birim-varyans'a normalize edilir (Wav2Vec2'nin beklediği biçim).
- Wav2Vec2 (donmuş).** Ön-eğitilmiş `facebook/wav2vec2-base` modeli **ince ayar YAPILMADAN**, yalnızca öznitelik çıkarıcı olarak kullanılır. Her klip için son gizli katman dizisi `[T, 768]` elde edilir.
- Zaman havuzlama.** Bu dizi zaman ekseninde üç istatistikle havuzlanır: ortalama (mean), standart sapma (std) ve maksimum (max). Birleştirilerek `[mean | std | max] = 3.768 = 2304` boyutlu bir vektör diske kaydedilir (cache).
- Öznitelik boyutu F (hiperparametre-1).** Bu cache dilimlenerek üç farklı boyut elde edilir: - **F = 768** : yalnız mean - **F = 1536** : mean + std - **F = 2304** : mean + std + max

PCA ve sınıflandırma

- Ölçekleme.** `StandardScaler` **yalnızca eğitim** kümesine uydurulur, geçerleme/test ona göre dönüştürülür (test istatistiği sızıntısı yok).
- PCA (hiperparametre-2, P).** Eğitim kümesine uydurulur; çıktı boyutu P taranır: **PCA yok / 32 / 64 / 128 / 256**. (Önce PCA'sız, sonra PCA ile.)
- KNN (hiperparametre-3, K).** `KNeighborsClassifier`, $K \in \{1, 3, 5, 7, 11, 15, 21, 31\}$. Geçerleme makro-F1'ine göre en iyi (F, P, K) seçilir; en iyi yapılandırma eğitim+geçerleme üzerine yeniden uydurulup test edilir.

Toplam ızgara: $3 (F) \times 5 (P) \times 8 (K) = 120$ kombinasyon / veri seti.

Deney Sonuçları Tablosu

Tam ızgara (3 F × 5 P × 8 K = 120 kombinasyon / veri seti) `odev1/outputs/<veri seti>/validation_grid.csv` içindedir. Aşağıda her (F, P) ikilisi için en iyi K satırı (geçerleme makro-F1'ine göre) özetlenmiştir. P = `none` PCA kullanılmadığı durumdur.

CREMA-D — geçerleme (her F×P için en iyi K):

Deney	F	P	K	Doğruluk	Makro-F1
1	768	128	15	0.476	0.463
2	768	256	15	0.466	0.454
3	768	64	15	0.466	0.453
4	768	none	15	0.461	0.450
5	768	32	31	0.454	0.438
6	1536	none	31	0.461	0.445
7	1536	256	31	0.459	0.441
8	1536	32	31	0.454	0.438
9	1536	128	15	0.446	0.428
10	1536	64	15	0.437	0.421
11	2304	256	15	0.481	0.468
12	2304	none	15	0.478	0.463
13	2304	128	15	0.473	0.459
14	2304	64	21	0.456	0.443
15	2304	32	31	0.451	0.434

MELD — geçerleme (her F×P için en iyi K):

Deney	F	P	K	Doğruluk	Makro-F1
1	768	128	5	0.256	0.246
2	768	256	5	0.259	0.243
3	768	none	5	0.249	0.233
4	768	32	5	0.244	0.229
5	768	64	5	0.239	0.225
6	1536	none	21	0.246	0.223
7	1536	32	21	0.239	0.218

Deney	F	P	K	Doğruluk	Makro-F1
8	1536	256	15	0.232	0.217
9	1536	128	15	0.229	0.213
10	1536	64	15	0.224	0.208
11	2304	256	15	0.239	0.226
12	2304	none	21	0.237	0.219
13	2304	64	21	0.237	0.217
14	2304	128	15	0.232	0.217
15	2304	32	5	0.217	0.210

Model Geçerleme


Hiperparametrelerin geçerleme başarımına etkisi (yukarıdaki tablolardan):

- **Öznitelik boyutu F.** CREMA-D'de en yüksek başarımlar **F = 2304** (mean+std+max) ile elde edildi; daha zengin istatistikler kontrollü/temiz kayıtlarda yardımcı oluyor. MELD'de ise tersine **F = 768** (yalnız mean) en iyi; gerçek-ortam gürültüsü altında ek istatistikler (std, max) gürültü taşıyıp KNN'i bozuyor (yüksek boyutta "boyut laneti" + sınırlı örnek).
- **PCA boyutu P.** Her iki veri setinde de **orta düzey PCA (128–256)** en iyi ya da PCA'sıza çok yakın; **agresif indirgeme (P = 32)** başarımları düşürüyor (bilgi kaybı). PCA'nın asıl faydası boyut/hız: 2304 → 256 ile ~%89 boyut azalması, başarımlar neredeyse korunarak (hatta hafif artarak) sağlanıyor.
- **Komşu sayısı K.** CREMA-D **K = 15** (orta), MELD **K = 5** (küçük) tercih ediyor. K = 1 her ikisinde de gürültüye duyarlı (aşırı uyum); çok büyük K (31) sınırları bulanıklaştırıyor. En iyi K, veri/ayrışabilirliğe göre orta bir değerde.


Test karşılaştırma tablosu (her veri setinin en iyisi):

Veri seti	F	P	K	Doğruluk	Dengeli doğr.	Makro-F1
CREMA-D	2304	256	15	0.480	0.480	0.466
MELD	768	128	5	0.205	0.206	0.194

Genel en iyi sonuç — karmaşıklık matrisi: CREMA-D (makro-F1 0.466). Aşağıda satır-normalize karmaşıklık matrisleri verilmiştir (her satır gerçek sınıfı, sütun tahmini gösterir; köşegen = doğru tahmin oranı).



Şekil 1. CREMA-D (genel en iyi). Köşegen değerleri görece yüksek; **angry** ve **neutral** en ayırt edilebilir, **fear** / **sad** arası karışma daha fazla.



Şekil 2. MELD. Tahminler büyük ölçüde baskın **neutral** sınıfına kayıyor; bu yüzden doğruluk görece yüksek görünse de makro-F1 düşük kalıyor (dengesizlik etkisi).

Sonuç ve Değerlendirme

Bu aşamada, Wav2Vec2 (donmuş) öznitelikleri üzerinde **KNN** ile konuşmadan duygu tanıma kuruldu ve üç hiperparametre (F, P, K) iki veri setinde ayrı ayrı tarandı.

- **KNN başarımı (denek-bağımsız, şans = %16.7).** CREMA-D'de en iyi yapılandırma test makro-F1 **0.466** (doğruluk %48.0) verdi — Wav2Vec2 özniteliklerinin duygu bilgisini taşıdığını, basit bir KNN

ile bile şansın ~3 katı başarıya ulaşıldığını gösteriyor. MELD'de en iyi makro-F1 **0.194** — gerçek-ortam koşulları (arka plan gürültüsü, değişken kayıt) ve güçlü sınıf dengesizliği (neutral baskın) nedeniyle belirgin biçimde daha zor.

- **Veri setleri arası fark.** CREMA-D (kontrollü/stüdyo) ile MELD (gerçek-ortam) arasındaki büyük başarımlar farkı, kayıt koşullarının duygu tanımayı doğrudan etkilediğini ortaya koyuyor; bu, bir sonraki aşamalarda incelenecek alan-kayması (domain shift) konusunun ön göstergesidir.
- **Hiperparametre çıkarımları.** (i) Öznitelik boyutu veri setine göre farklı optimum veriyor: temiz veride zengin (2304), gürültülü veride sade (768) öznitelik daha iyi. (ii) Orta düzey PCA boyut/başarımlar dengesini iyi kuruyor; agresif indirgeme zararlı. (iii) Orta bir K (5–15) en iyi; aşırı küçük/büyük K başarımları düşürüyor.
- **Metrik notu.** MELD dengesiz olduğundan doğruluk yanıltıcıdır; **makro-F1** ve **dengeli doğruluk** gerçek başarımları yansıtır (karmaşıklık matrisinde tahminlerin baskın sınıfa kayması görülür).

Kapsam notu (ilerleme raporu). Bu ilk aşamada KNN hiperparametre çalışması, hesaplama süresini sınırlamak için her veri setinden **dengeli bir altküme** (CREMA-D 2.480 + MELD 2.719 = 5.199 kayıt) üzerinde, denek-bağımsız bölmeyle yürütülmüştür. Wav2Vec2 öznitelik çıkarımı tüm veri için yeniden çalıştırılabilir (resumable cache) ve sonraki aşamalarda tam veriye genişletilecektir.