

Tablo ve başlıklar ders sablonuna göre doldurulmuştur.

Erisim Bilgileri

Oğrenci: Ahmet Babagil - 211101067

Orijinal Veri Seti Adı: CREMA-D ve MELD

Orijinal Veri Seti Bağlantısı:

- CREMA-D: <https://github.com/CheyneyComputerScience/CREMA-D>
- CREMA-D ses aynası: <https://huggingface.co/datasets/AbstractTTS/CREMA-D>
- MELD: <https://github.com/declare-lab/MELD>
- MELD raw veri: <http://web.eecs.umich.edu/~mihalcea/downloads/MELD.Raw.tar.gz>

Proje Çalışmasının Yuklendiği Google Drive Bağlantısı:

- <https://drive.google.com/drive/folders/1Hbp4WtCGFZjpvQCDxFmqtOmeqq-SMPvW?usp=sharing>

Kod / GitHub Deposu:

- <https://github.com/AhmetBabagil/speech-emotion-recognition/tree/feat/speech-emotion-recognition>

İlk aşamada kullanılan veri setleri değiştirilmedi. Drive teslim klasörüne proje dosyalarıyla birlikte `veri_seti_ses.zip` veri seti arşivi de konuldu; ayrıca orijinal veri seti bağlantıları ve indirme/manifest oluşturma kodları yukarıda verildi. Proje kodu, deney çıktıları, rapor dosyaları, validation gridleri, test sonuçları ve karmaşıklık matrisleri `odev2` klasöründe hazırlandı.

Çalıştırılacak Dosyalar ve Ne Yaptıkları:

Dosya	Görev
<code>odev1/extract.py</code>	Ses dosyalarından donmuş Wav2Vec2 özelliklerini çıkarır ve cache'e kaydeder. Bu adım pahalı olduğu için 1. aşamadaki cache tekrar kullanıldı.
<code>odev2/run_experiment.py</code>	CREMA-D ve MELD için Decision Tree, Random Forest ve Gradient Boosting validasyon gridlerini çalıştırır; en iyi modeli train+validation ile yeniden eğitip test setinde ölçer.
<code>odev2/model_pipeline.py</code>	Veri bölme, StandardScaler, PCA, model kurma, class weight/sample weight, validation seçimi, test metrikleri ve karmaşıklık matrisi üretimini içerir.
<code>odev2/build_report.py</code>	Deney çıktılarından rapor tabloları, test karşılaştırmaları ve otomatik bulguları üretir.
<code>odev2/SONUCLAR.ipynb</code>	Test karşılaştırmalarını, validation kapsamını ve karmaşıklık matrislerini Jupyter formatında gösterir.

Çalıştırma komutları:

```
python odev2/run_experiment.py --manifest odev1/manifest_subset.csv --grid-mode report
python odev2/build_report.py
```

Veri Seti ve Değerlendirme Metrikleri

Projede konuşmadan duygu tanıma problemi ele alındı. İki veri seti kullanıldı:

Veri seti	Kısa açıklama	Ortak sınıflar
CREMA-D	Kontrollü/stüdyo ortamında kaydedilmiş oyuncu konuşmaları	angry, disgust, fear, happy, neutral, sad
MELD	TV diyaloglarından gelen daha doğal ve gürültülü konuşmalar	angry, disgust, fear, happy, neutral, sad

MELD veri setindeki `surprise` sınıfı CREMA-D ile ortak olmadığı için çıkarıldı. İki veri seti de aynı 6 duygu sınıfı üzerinde değerlendirildi.

Eğitim, geçerleme ve test bolmeleri konuşmaci bağımsız yapıldı. Aynı konuşmaci train, validation ve test bölümlerinde birlikte bulunmadı. Bu tercih, modelin aynı konuşmacinin ses özelliklerini ezberlemesini engellemek için kullanıldı.

Değerlendirme metrikleri:

- Accuracy
- Balanced accuracy
- Macro-F1
- Weighted-F1
- Sınıf bazlı precision/recall/F1
- Karmaşıklik matrisi

Ana model seçim metriği validation macro-F1 olarak belirlendi. Veri setlerinde sınıf dağılımı ve sınıfların zorlukları farklı olduğu için accuracy tek başına yeterli görülmedi; macro-F1 ve balanced accuracy özellikle raporlandı.

Yöntem

Ses kayıtları önce Wav2Vec2 tabanlı donmuş öznetelik çıkarıcı ile vektörlere dönüştürüldü. Bu aşamada Wav2Vec2 modeli eğitilmedi; yalnızca her ses girdisi için sabit uzunluklu öznetelik vektörü elde edildi.

Öznetelik vektörü için üç farklı havuzlama/boyut seçeneği hiperparametre olarak denendi:

F	Anlamı
768	Wav2Vec2 zaman eksenini mean havuzlama
1536	mean + std havuzlama
2304	mean + std + max havuzlama

PCA oncesinde StandardScaler uygulandi. StandardScaler ve PCA yalnızca eğitim verisine fit edildi; validation ve test setlerine sadece transform uygulandi. Bu şekilde validation/test bilgisi eğitim aşamasına sızdırılmadı.

PCA boyutu da hiperparametre olarak ele alındı. Decision Tree ve Random Forest için `none`, `64`, `128`, `256`; Gradient Boosting için çalışma süresi nedeniyle `none` ve `64` seçenekleri denendi. PCA uygulanmayan durumda model doğrudan normalize edilmiş Wav2Vec2 vektörleri üzerinde eğitildi.

Sınıf dengesizliği için Decision Tree ve Random Forest modellerinde `class_weight="balanced"` kullanıldı. Gradient Boosting modelinde aynı amaçla `sample_weight` kullanıldı.

Model Gecerleme

F: Öznitelik vektörü boyutu

P: PCA çıktı vektörü boyutu (`none` PCA uygulanmadığını gösterir)

X: Modelin ana hiperparametresi 1

Y: Modelin ana hiperparametresi 2

Z: Modelin ana hiperparametresi 3; Gradient Boosting için iki ana hiperparametre olduğundan Z yoktur.

Model bazında X/Y/Z karşılıkları:

Model	X	Y	Z
Decision Tree	criterion	max_depth	min_samples_split
Random Forest	n_estimators	max_depth	max_features
Gradient Boosting	learning_rate	max_depth	-

Hiperparametre seçimi test setine bakmadan yapıldı. Her veri seti ve model için validation grid çalıştırıldı. En iyi kombinasyon önce validation macro-F1'a göre, eşitlik durumunda balanced accuracy ve accuracy değerlerine göre seçildi. Seçilen kombinasyon daha sonra train + validation verisi üzerinde yeniden eğitildi ve test seti yalnızca final değerlendirme için kullanıldı.

Deney kapsamı:

Veri seti	Model	Denenen kombinasyon sayısı
CREMA-D	Decision Tree	216
CREMA-D	Random Forest	72
CREMA-D	Gradient Boosting	24
MELD	Decision Tree	216
MELD	Random Forest	72
MELD	Gradient Boosting	24

Asagidaki tablolar, her veri seti-model ikilisi icin validation macro-F1'a gore en iyi kombinasyonlari gostermektedir. Tam grid dosyalari `odev2/outputs/<veri_seti>/_validation_grid.csv` altinda saklandi.

CREMA-D - Karar Agaci validasyon

Sira	F	PCA	Hiperparametreler	Val dogr.	Val dengeli dogr.	Val makro-F1
1	1536	none	criterion=entropy, max_depth=8, min_samples_split=10	0.4049	0.4056	0.4031
2	1536	none	criterion=log_loss, max_depth=8, min_samples_split=10	0.4049	0.4056	0.4031
3	1536	none	criterion=entropy, max_depth=16, min_samples_split=2	0.3902	0.3881	0.3859
4	1536	none	criterion=log_loss, max_depth=16, min_samples_split=2	0.3902	0.3881	0.3859
5	1536	none	criterion=entropy, max_depth=8, min_samples_split=2	0.3902	0.3917	0.3851
6	1536	none	criterion=log_loss, max_depth=8, min_samples_split=2	0.3902	0.3917	0.3851
7	1536	none	criterion=entropy, max_depth=None, min_samples_split=10	0.3829	0.3806	0.3804
8	1536	none	criterion=entropy, max_depth=16, min_samples_split=10	0.3829	0.3806	0.3804
9	1536	none	criterion=log_loss, max_depth=None, min_samples_split=10	0.3829	0.3806	0.3804
10	1536	none	criterion=log_loss, max_depth=16, min_samples_split=10	0.3829	0.3806	0.3804
11	2304	none	criterion=entropy, max_depth=8, min_samples_split=10	0.3829	0.3849	0.378
12	2304	none	criterion=log_loss, max_depth=8, min_samples_split=10	0.3829	0.3849	0.378

CREMA-D - Gradient Boosting validasyon

Sira	F	PCA	Hiperparametreler	Val dogr.	Val dengeli dogr.	Val makro- F1
1	1536	none	learning_rate=0.1, max_depth=3	0.5244	0.5226	0.5238

Sıra	F	PCA	Hiperparametreler	Val dogr.	Val dengeli dogr.	Val makro- F1
2	1536	none	learning_rate=0.05, max_depth=3	0.522	0.5206	0.5151
3	768	none	learning_rate=0.1, max_depth=3	0.5073	0.5052	0.5043
4	2304	none	learning_rate=0.1, max_depth=3	0.5098	0.5056	0.5016
5	768	none	learning_rate=0.05, max_depth=3	0.5024	0.5016	0.4966
6	2304	none	learning_rate=0.05, max_depth=3	0.5024	0.5008	0.4949
7	2304	none	learning_rate=0.1, max_depth=1	0.4976	0.496	0.4858
8	1536	none	learning_rate=0.1, max_depth=1	0.4927	0.4913	0.4808
9	768	none	learning_rate=0.1, max_depth=1	0.4854	0.4825	0.478
10	768	64	learning_rate=0.05, max_depth=3	0.478	0.4786	0.4683
11	768	64	learning_rate=0.1, max_depth=3	0.4756	0.475	0.4664
12	2304	64	learning_rate=0.1, max_depth=3	0.4732	0.475	0.4629

CREMA-D - Rastgele Orman validasyon

Sıra	F	PCA	Hiperparametreler	Val dogr.	Val dengeli dogr.	Val makro-F1
1	1536	none	max_depth=16, max_features=log2, n_estimators=100	0.5049	0.5048	0.4964
2	2304	none	max_depth=24, max_features=sqrt, n_estimators=100	0.5049	0.5028	0.4941
3	768	none	max_depth=None, max_features=log2, n_estimators=100	0.5	0.4984	0.4924
4	768	none	max_depth=24, max_features=log2, n_estimators=100	0.5	0.498	0.4923
5	2304	none	max_depth=None, max_features=sqrt, n_estimators=100	0.5024	0.5004	0.4904
6	2304	128	max_depth=16, max_features=log2, n_estimators=100	0.5	0.5004	0.487
7	1536	none	max_depth=24, max_features=log2, n_estimators=100	0.5	0.4972	0.4863

Sıra	F	PCA	Hiperparametreler	Val dogr.	Val dengeli dogr.	Val makro-F1
8	1536	none	max_depth=None, max_features=log2, n_estimators=100	0.5	0.4976	0.4859
9	768	none	max_depth=16, max_features=log2, n_estimators=100	0.4951	0.494	0.4841
10	2304	64	max_depth=24, max_features=log2, n_estimators=100	0.4927	0.4909	0.4821
11	2304	none	max_depth=16, max_features=log2, n_estimators=100	0.4927	0.4909	0.4807
12	1536	none	max_depth=None, max_features=sqrt, n_estimators=100	0.4927	0.4913	0.4804

MELD - Karar Agaci validasyon

Sıra	F	PCA	Hiperparametreler	Val dogr.	Val dengeli dogr.	Val makro-F1
1	768	128	criterion=gini, max_depth=8, min_samples_split=10	0.2512	0.2579	0.2492
2	768	128	criterion=gini, max_depth=8, min_samples_split=2	0.2488	0.2549	0.2461
3	768	64	criterion=gini, max_depth=None, min_samples_split=2	0.2365	0.2313	0.2299
4	768	64	criterion=gini, max_depth=8, min_samples_split=2	0.2291	0.2349	0.2285
5	768	64	criterion=gini, max_depth=8, min_samples_split=10	0.2291	0.2348	0.2283
6	768	64	criterion=entropy, max_depth=16, min_samples_split=2	0.2266	0.2221	0.2223
7	768	64	criterion=log_loss, max_depth=16, min_samples_split=2	0.2266	0.2221	0.2223
8	768	64	criterion=gini, max_depth=16, min_samples_split=2	0.2266	0.2218	0.2203
9	768	64	criterion=entropy, max_depth=None, min_samples_split=10	0.2266	0.2177	0.217
10	768	64	criterion=entropy, max_depth=16, min_samples_split=10	0.2266	0.2177	0.217

Sıra	F	PCA	Hiperparametreler	Val dogr.	Val dengeli dogr.	Val makro-F1
11	768	64	criterion=log_loss, max_depth=None, min_samples_split=10	0.2266	0.2177	0.217
12	768	64	criterion=log_loss, max_depth=16, min_samples_split=10	0.2266	0.2177	0.217

MELD - Gradient Boosting validasyon

Sıra	F	PCA	Hiperparametreler	Val dogr.	Val dengeli dogr.	Val makro- F1
1	1536	64	learning_rate=0.1, max_depth=3	0.2365	0.2312	0.2268
2	2304	none	learning_rate=0.05, max_depth=3	0.234	0.2251	0.2234
3	768	none	learning_rate=0.1, max_depth=3	0.2291	0.2193	0.2204
4	1536	none	learning_rate=0.1, max_depth=3	0.2241	0.2172	0.2185
5	768	64	learning_rate=0.1, max_depth=1	0.2365	0.2232	0.215
6	1536	64	learning_rate=0.05, max_depth=3	0.2192	0.2172	0.2138
7	768	64	learning_rate=0.05, max_depth=3	0.2241	0.2157	0.212
8	2304	none	learning_rate=0.1, max_depth=1	0.2291	0.2216	0.2112
9	1536	none	learning_rate=0.05, max_depth=3	0.234	0.2157	0.2082
10	2304	64	learning_rate=0.1, max_depth=1	0.2241	0.2135	0.2046
11	2304	64	learning_rate=0.05, max_depth=3	0.2143	0.2061	0.202
12	768	64	learning_rate=0.05, max_depth=1	0.2241	0.2109	0.201

MELD - Rastgele Orman validasyon

Sıra	F	PCA	Hiperparametreler	Val dogr.	Val dengeli dogr.	Val makro-F1
1	2304	64	max_depth=16, max_features=sqrt, n_estimators=100	0.2586	0.2379	0.2349

Sıra	F	PCA	Hiperparametreler	Val dogr.	Val dengeli dogr.	Val makro-F1
2	768	128	max_depth=None, max_features=log2, n_estimators=100	0.2389	0.2323	0.234
3	1536	64	max_depth=None, max_features=log2, n_estimators=100	0.2537	0.2355	0.2333
4	768	64	max_depth=24, max_features=sqrt, n_estimators=100	0.2537	0.2342	0.2295
5	2304	256	max_depth=None, max_features=log2, n_estimators=100	0.2414	0.2277	0.2274
6	2304	128	max_depth=None, max_features=sqrt, n_estimators=100	0.2611	0.2341	0.2246
7	1536	128	max_depth=24, max_features=sqrt, n_estimators=100	0.2365	0.2211	0.2228
8	1536	128	max_depth=None, max_features=sqrt, n_estimators=100	0.2488	0.2264	0.2224
9	2304	128	max_depth=16, max_features=log2, n_estimators=100	0.2389	0.2213	0.2202
10	1536	64	max_depth=16, max_features=sqrt, n_estimators=100	0.234	0.2213	0.2198
11	768	128	max_depth=None, max_features=sqrt, n_estimators=100	0.234	0.22	0.2186
12	1536	128	max_depth=16, max_features=log2, n_estimators=100	0.234	0.2187	0.2185

2. asama modelleri test karsilastirmasi

Veri seti	Model	F	PCA	Hiperparametreler	Test dogr.	Test dengeli dogr.	Test makro- F1	Test agirlikli- F1
CREMA-D	Gradient Boosting	1536	none	learning_rate=0.1, max_depth=3	0.5202	0.5179	0.5144	0.5153
CREMA-D	Rastgele Orman	1536	none	max_depth=16, max_features=log2, n_estimators=100	0.486	0.484	0.4721	0.4717
CREMA-D	Karar Agaci	1536	none	criterion=entropy, max_depth=8, min_samples_split=10	0.3614	0.361	0.3496	0.3494

Veri seti	Model	F	PCA	Hiperparametreler	Test dogr.	Test dengeli dogr.	Test makro- F1	Test agirlikli- F1
MELD	Gradient Boosting	1536	64	learning_rate=0.1, max_depth=3	0.2093	0.2072	0.2027	0.2068
MELD	Rastgele Orman	2304	64	max_depth=16, max_features=sqrt, n_estimators=100	0.2116	0.2146	0.2006	0.2004
MELD	Karar Agaci	768	128	criterion=gini, max_depth=8, min_samples_split=10	0.1465	0.1475	0.143	0.1463

KNN dahil genel test karsilastirmasi

Veri seti	Model	F	PCA	Hiperparametreler	Test dogr.	Test dengeli dogr.	Test makro- F1	Test agirlikli- F1
CREMA-D	Gradient Boosting	1536	none	learning_rate=0.1, max_depth=3	0.5202	0.5179	0.5144	0.5153
CREMA-D	Rastgele Orman	1536	none	max_depth=16, max_features=log2, n_estimators=100	0.486	0.484	0.4721	0.4717
CREMA-D	KNN (Odev 1)	2304	256	K=15	0.4798	0.4803	0.4657	0.4641
CREMA-D	Karar Agaci	1536	none	criterion=entropy, max_depth=8, min_samples_split=10	0.3614	0.361	0.3496	0.3494
MELD	Gradient Boosting	1536	64	learning_rate=0.1, max_depth=3	0.2093	0.2072	0.2027	0.2068
MELD	Rastgele Orman	2304	64	max_depth=16, max_features=sqrt, n_estimators=100	0.2116	0.2146	0.2006	0.2004
MELD	KNN (Odev 1)	768	128	K=5	0.2047	0.2063	0.1941	0.1938
MELD	Karar Agaci	768	128	criterion=gini, max_depth=8, min_samples_split=10	0.1465	0.1475	0.143	0.1463

Otomatik bulgular

- CREMA-D için en iyi model Gradient Boosting (test makro-F1=0.5144).
- MELD için en iyi model Gradient Boosting (test makro-F1=0.2027).
- Genel en iyi sonuç CREMA-D veri setinde Gradient Boosting ile elde edildi (test makro-F1=0.5144).

Deney Sonuçları ve Değerlendirme

Test sonuçları incelendiğinde CREMA-D veri setinde en iyi performans Gradient Boosting ile elde edildi. Bu model test macro-F1 = 0.5144 değerine ulaştı. Random Forest ikinci sırada kalırken, tek Decision Tree modeli daha düşük performans verdi. Bu sonuç, tek ağac modelinin yüksek boyutlu ses özelliklerinde yeterince genelleylemediğini; ensemble tabanlı yöntemlerin daha kararlı olduğunu göstermektedir.


MELD veri setinde genel performans CREMA-D'ye göre belirgin şekilde düşüktür. Bunun temel nedeni MELD'in TV diyaloglarından gelmesi, kayıt koşullarının daha doğal/gürültülü olması ve duygu sınıflarının daha zor ayrılmasıdır. MELD üzerinde de en yüksek test macro-F1 değeri Gradient Boosting ile elde edildi: 0.2027. Random Forest çok yakın bir sonuç verdi; KNN ise bu iki modele yakın fakat biraz daha düşük kaldı.

KNN dahil genel karşılaştırmada CREMA-D için Gradient Boosting, 1. aşamadaki KNN sonucunu geçti. MELD için de Gradient Boosting en yüksek macro-F1'i verdi. Bu nedenle genel en iyi model Gradient Boosting olarak değerlendirildi. Ancak MELD sonuçlarının düşük olması, sonraki aşamada daha güçlü özellik çıkarımı, veri artırma veya veri seti özelinde daha uygun modeller denenmesi gerektiğini göstermektedir.


Karışıklık matrisleri aşağıda ve `odev2/outputs/<veri_seti>/*_confusion_matrix.png` dosyalarında verildi. CREMA-D matrislerinde sınıfların MELD'e göre daha iyi ayrıldığı görülmektedir. MELD'de sınıflar arası karışma daha yüksektir; bu da macro-F1 değerinin düşük kalmasına neden olmuştur.

CREMA-D Karışıklık Matrisleri

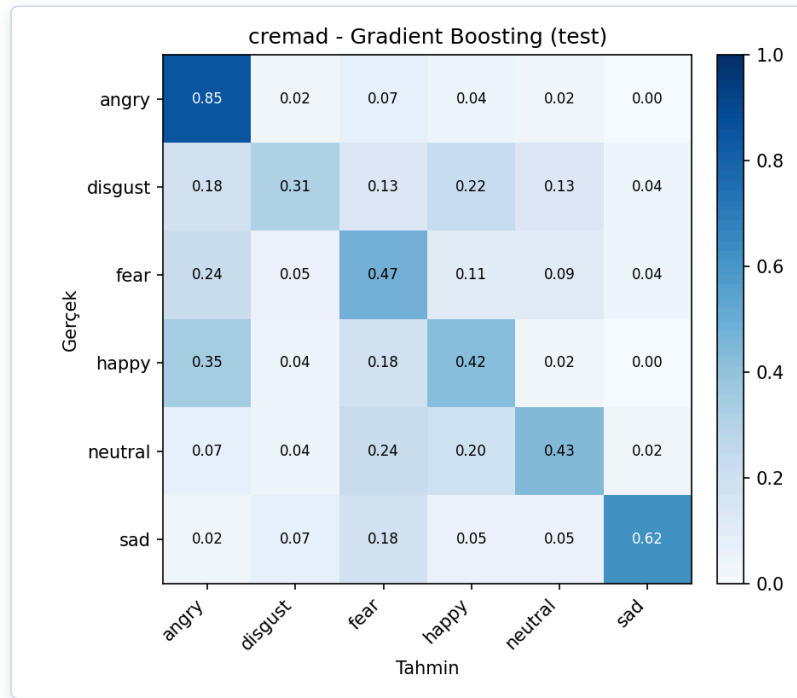
Decision Tree:



Random Forest:




Gradient Boosting:




MELD Karmaşık Matrisleri

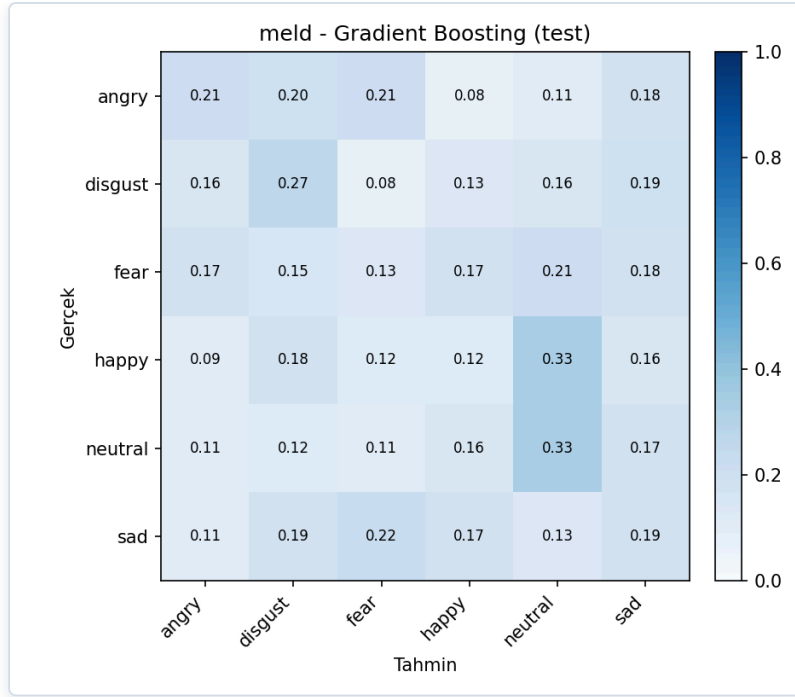
Decision Tree:



Random Forest:



Gradient Boosting:



Sonuc ve Ileride Yapilacaklar

Bu asamada iki veri seti icin uc farkli makine ogrenimi modeli gelistirildi ve karsilastirildi: Decision Tree, Random Forest ve Gradient Boosting. Her model icin oznitelik boyutu, PCA boyutu ve model hiperparametreleri validation seti uzerinde sistematik olarak arandi. Test seti yalnızca final degerlendirme icin kullanildi.

Sonuc, ensemble tabanlı modellerin tek karar agacina gore daha basarili oldugunu gosterdi. CREMA-D uzerinde en iyi sonuc Gradient Boosting ile elde edildi. MELD veri setinde performans daha dusuk kaldı; bu durum veri setinin dogal/gurultulu yapisindan ve duygu siniflarinin daha zor ayrilmasindan kaynaklanmaktadır.

Sonraki asamada yapilabilecekler:

- MELD icin daha guclu veya veri setine daha uygun oznitelik cikarimi denemek.
- Wav2Vec2 vektorleri disinda farkli ses temsilleriyle karsilastirma yapmak.
- Sinif bazli hata analizini karmasiklik matrisleri uzerinden detaylandirmek.
- Daha genis hiperparametre aramasi veya daha verimli arama stratejileri denemek.
- CREMA-D ve MELD arasindaki domain farkini azaltacak yontemler uzerinde calismak.